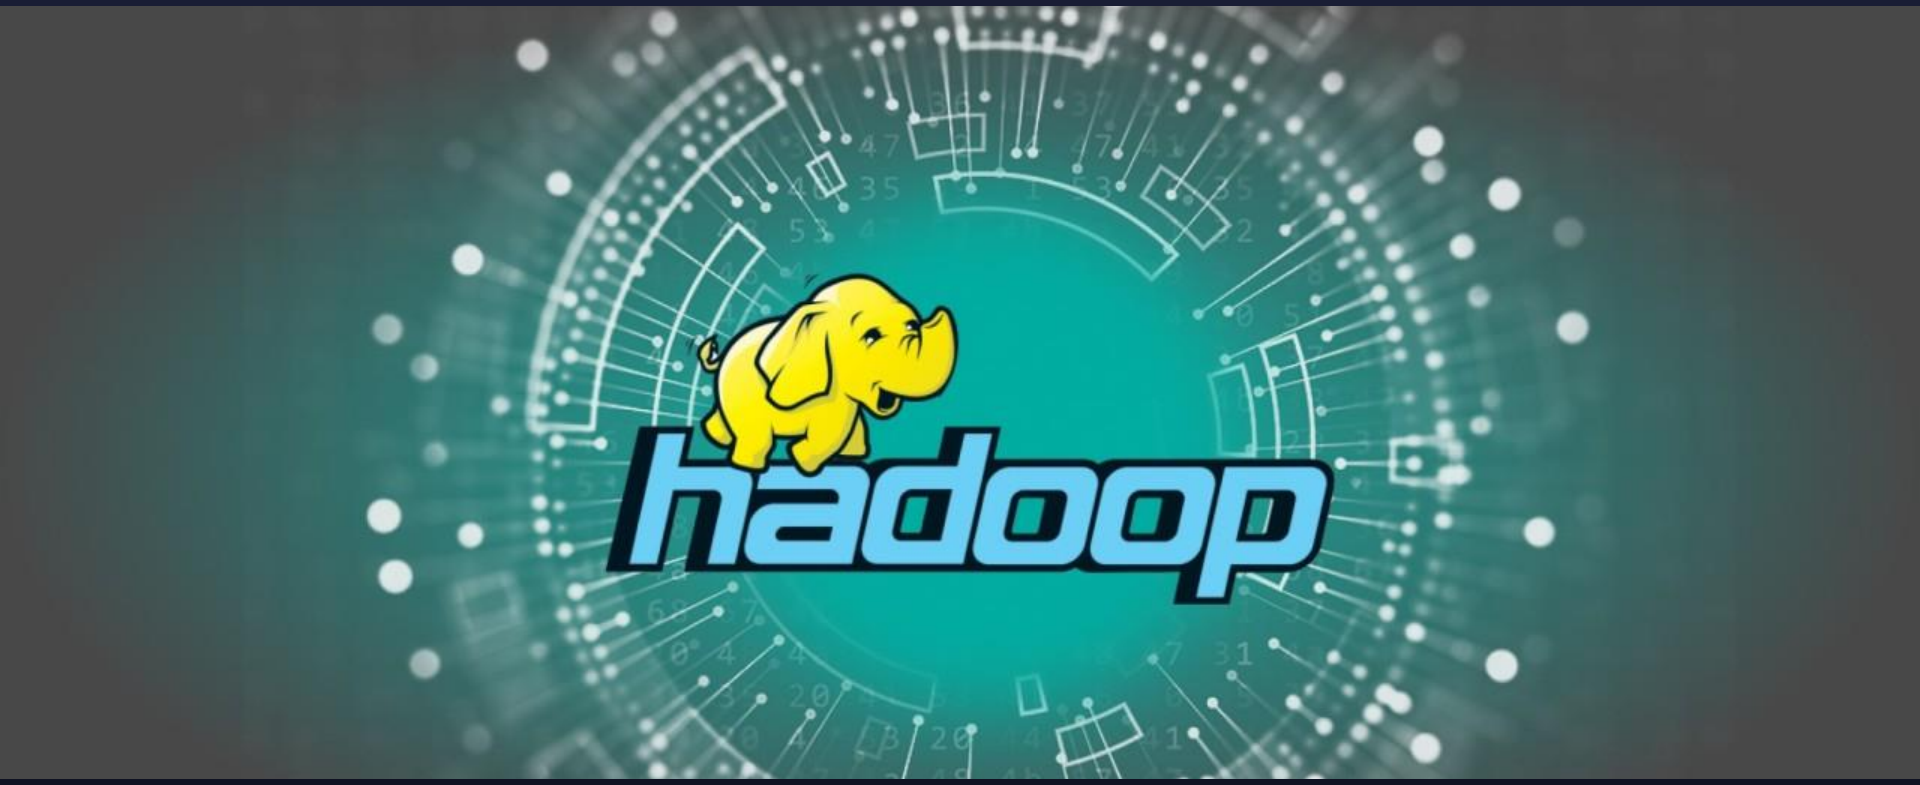
IES SAN ANDRÉS

ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL Y BIG DATA

BIG DATA APLICADO



UT01: INTRODUCCIÓN AL BIG DATA Y PARADIGMAS DISTRIBUIDOS

ÍNDICE

1.- Contexto y motivación

2.- Apache Hadoop, ¿qué es?

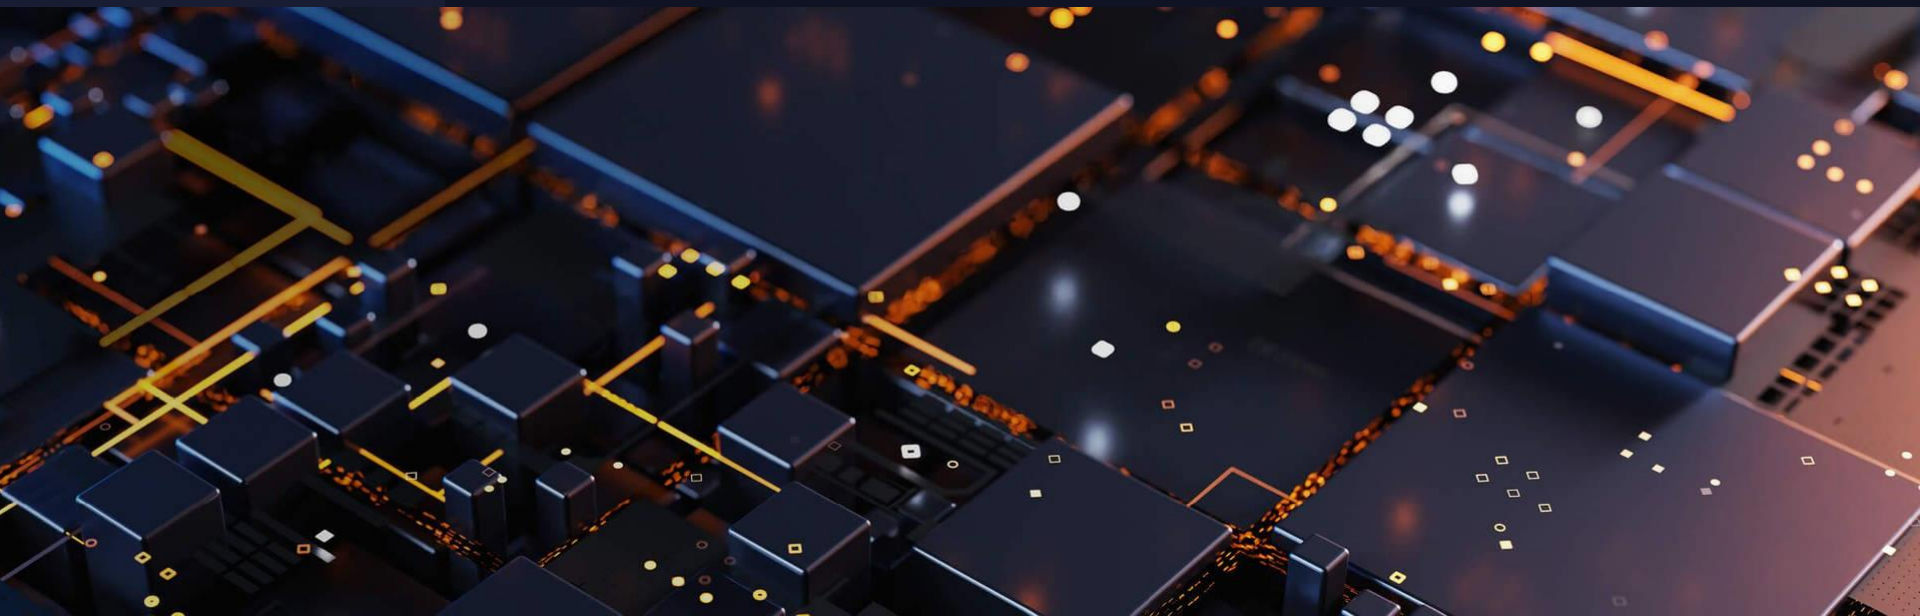
3.- Apache Hadoop, historia

4.- Apache Hadoop, problemas que resuelve

5.- AWS, ¿qué es?

6.- AWS, historia y principales servicios

1 CONTEXTO Y MOTIVACIÓN



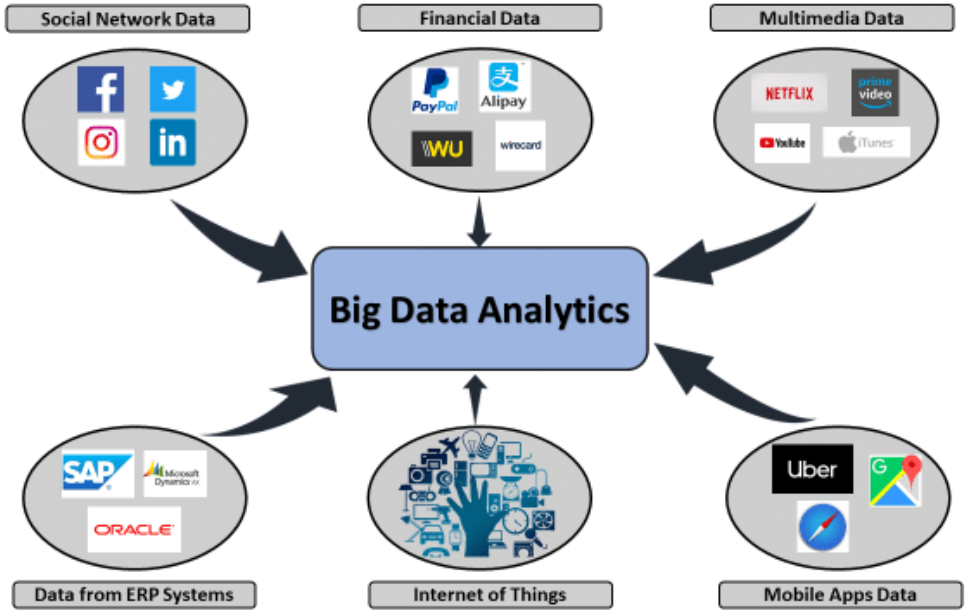
EL CRECIMIENTO DEL BIG DATA

Víctor J. González

En las últimas décadas, el volumen de datos ha crecido exponencialmente.

Múltiples fuentes de datos:

- Redes sociales
- Sensores IoT
- Registros de transacciones
- Sistemas empresariales
- Vídeos
- Imágenes
- Logs de aplicaciones
- …



EL CRECIMIENTO DEL BIG DATA

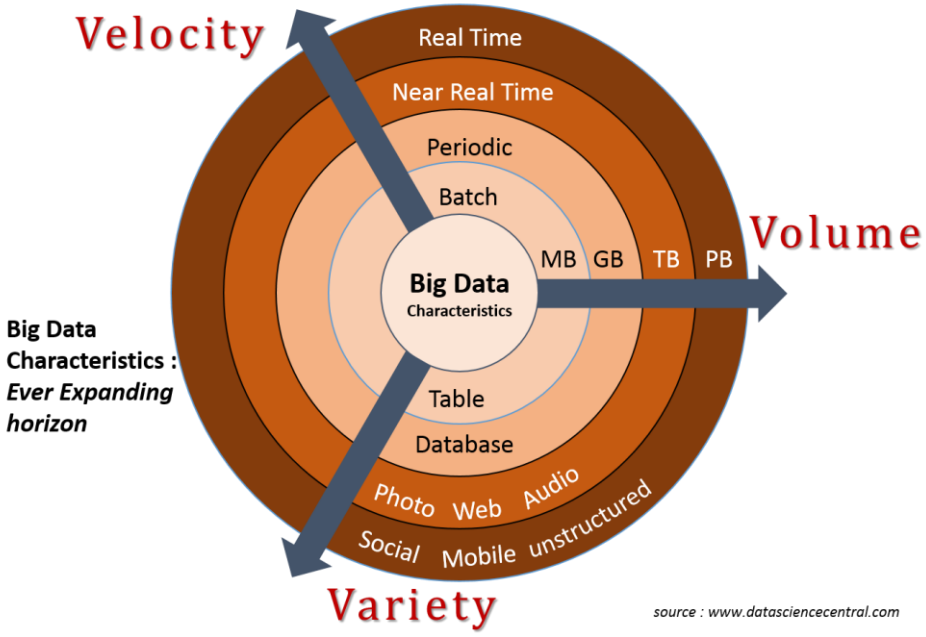
Víctor J. González

Este fenómeno se llama **Big Data** y se caracteriza por las 3V

Volumen: se generan ingentes cantidades de datos de forma constante.

Velocidad: los datos se producen y necesitan procesarse en tiempo real o casi real

Variedad: los datos pueden ser estructurados (tablas), semiestructurados (JSON, XML) o no estructurados (texto libre, imágenes, vídeo)



Las soluciones tradicionales (como BBDD relacionales o los sistemas monolíticos) tienen serias **limitaciones** para manejar eficientemente este nuevo paradigma.

LIMITACIONES SISTEMAS TRADICIONALES

Víctor J. González

Los sistemas tradicionales diseñados para:

Diseñados para

- Entornos controlados
- Volúmenes de datos moderados
- Alta estructura
- Bajo nivel de concurrencia masiva

LIMITACIONES SISTEMAS TRADICIONALES

Víctor J. González

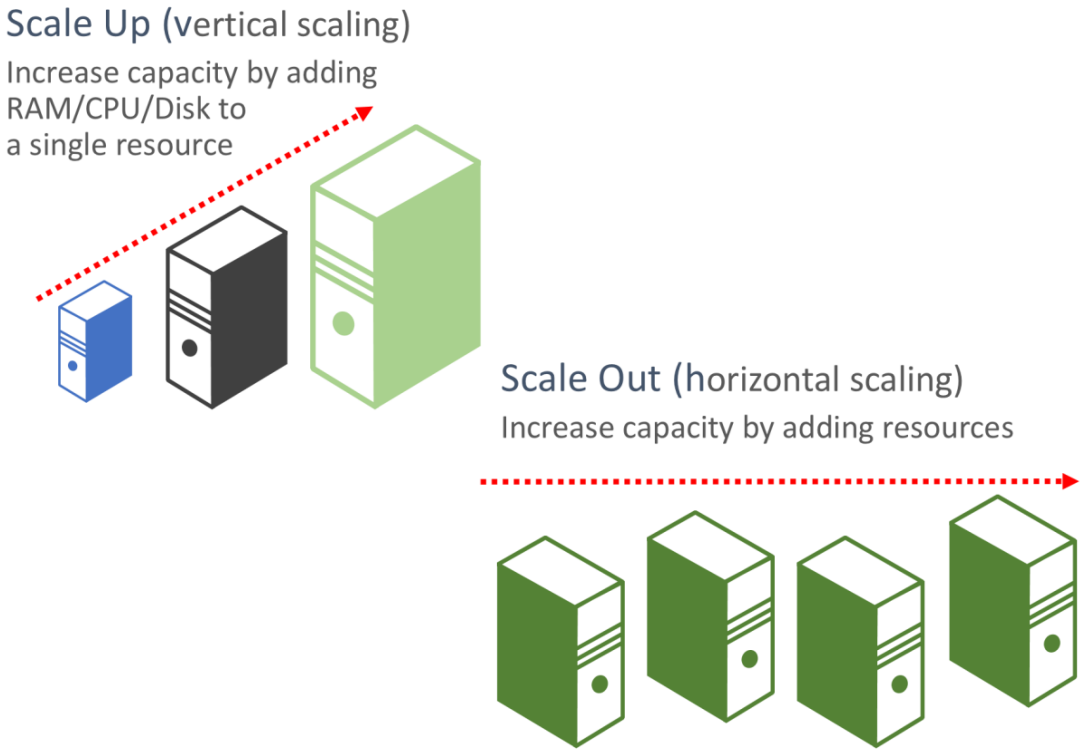
Los sistemas tradicionales diseñados para:

Diseñados para

- Entornos controlados
- Volúmenes de datos moderados
- Alta estructura
- Bajo nivel de concurrencia masiva

Limitaciones

1 **Escalabilidad vertical limitada**: para mejorar el rendimiento requieren hardware más potente. Costoso y no escalable a largo plazo



LIMITACIONES SISTEMAS TRADICIONALES

Víctor J. González

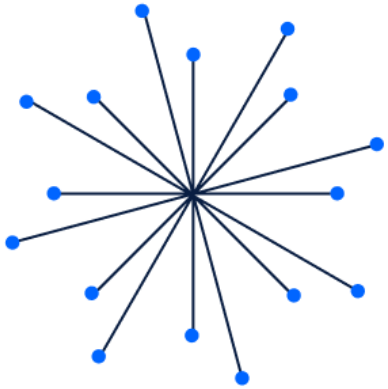
Los sistemas tradicionales diseñados para:

Diseñados para

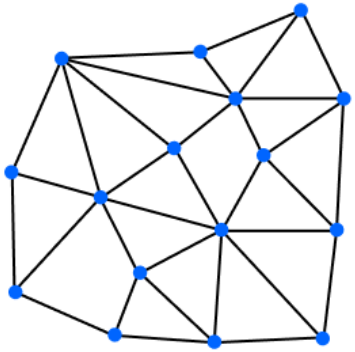
- Entornos controlados
- Volúmenes de datos moderados
- Alta estructura
- Bajo nivel de concurrencia masiva

Limitaciones

2 **Procesamiento centralizado**: los datos se suelen almacenarse y procesarse en un único nodo o servidor, lo que supone un cuello de botella.



Centralized



Distributed

LIMITACIONES SISTEMAS TRADICIONALES

Víctor J. González

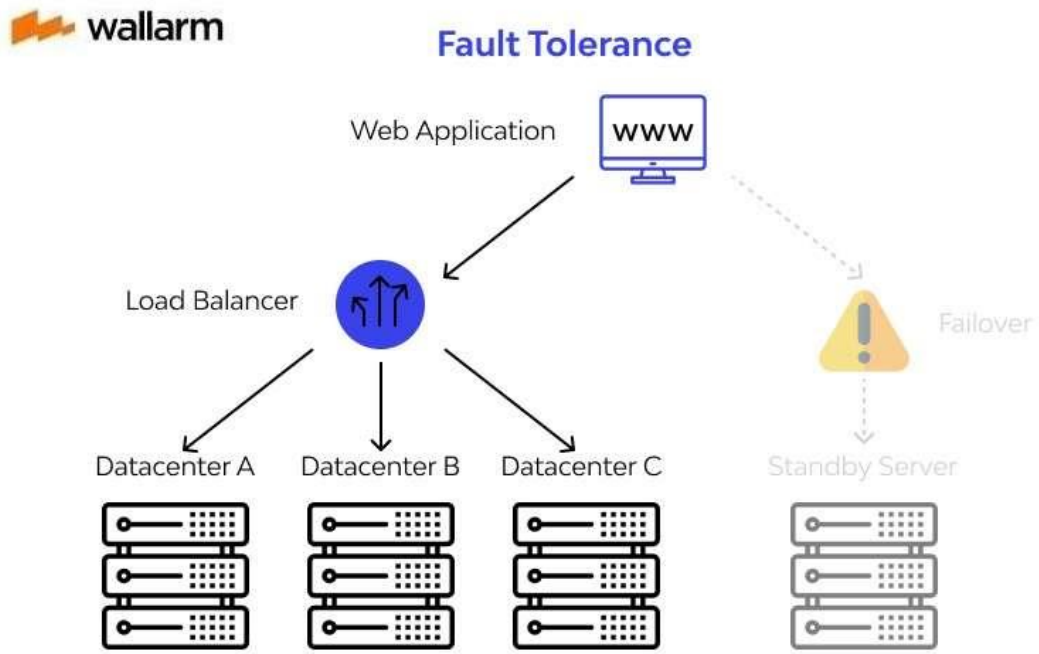
Los sistemas tradicionales diseñados para:

Diseñados para

- Entornos controlados
- Volúmenes de datos moderados
- Alta estructura
- Bajo nivel de concurrencia masiva

Limitaciones

3 **Falta de tolerancia a fallos**: si el nodo central falla, el sistema completo puede dejar de funcionar



LIMITACIONES SISTEMAS TRADICIONALES

Víctor J. González

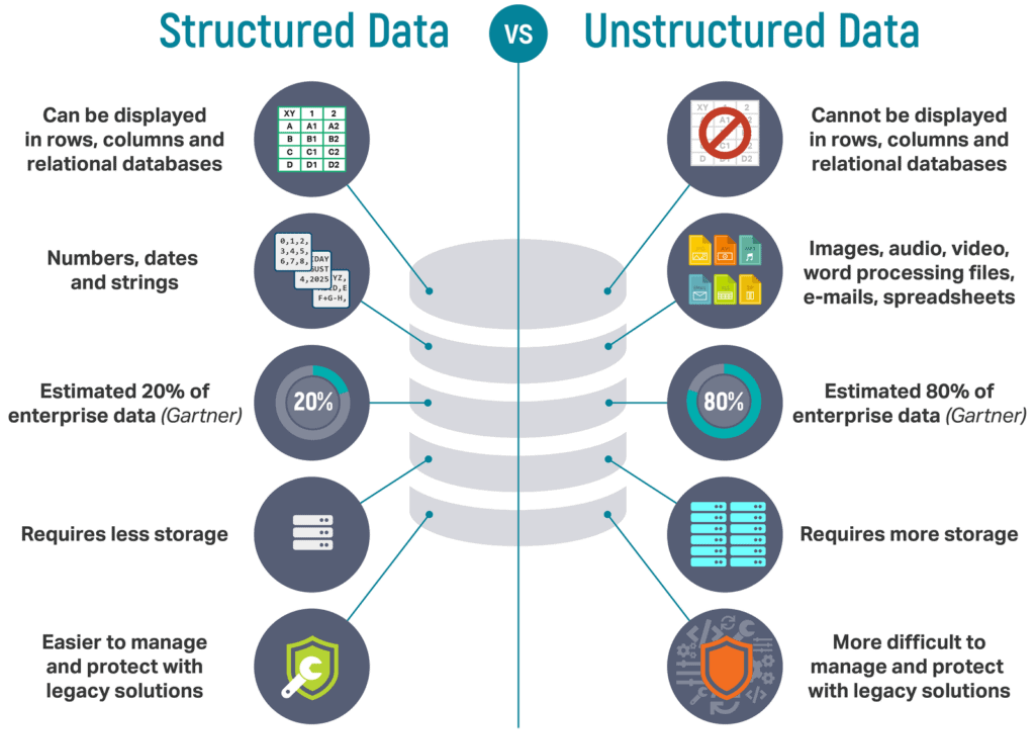
Los sistemas tradicionales diseñados para:

Diseñados para

- Entornos controlados
- Volúmenes de datos moderados
- Alta estructura
- Bajo nivel de concurrencia masiva

Limitaciones

4 **Dificultad para trabajar con datos semiestruturados o no estructurados**: los RDBMS están diseñados para datos altamente estructurados.



LIMITACIONES SISTEMAS TRADICIONALES

Víctor J. González

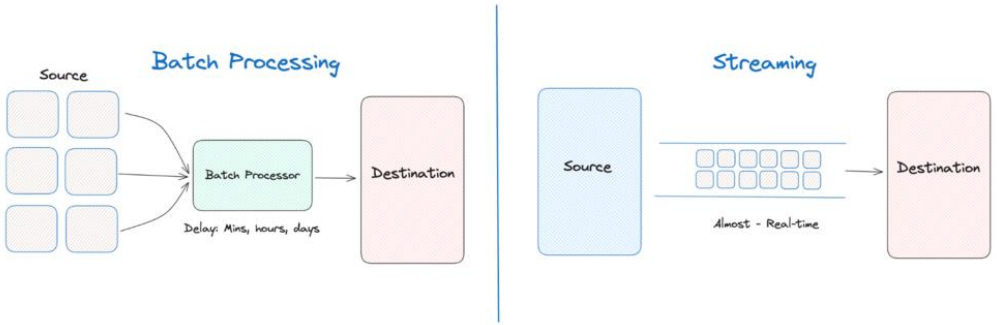
Los sistemas tradicionales diseñados para:

Diseñados para

- Entornos controlados
- Volúmenes de datos moderados
- Alta estructura
- Bajo nivel de concurrencia masiva

Limitaciones

5 **Procesamiento batch lento**: el análisis de grandes volúmenes de datos puede llevar horas o días



Streaming vs Batch Processing

decube

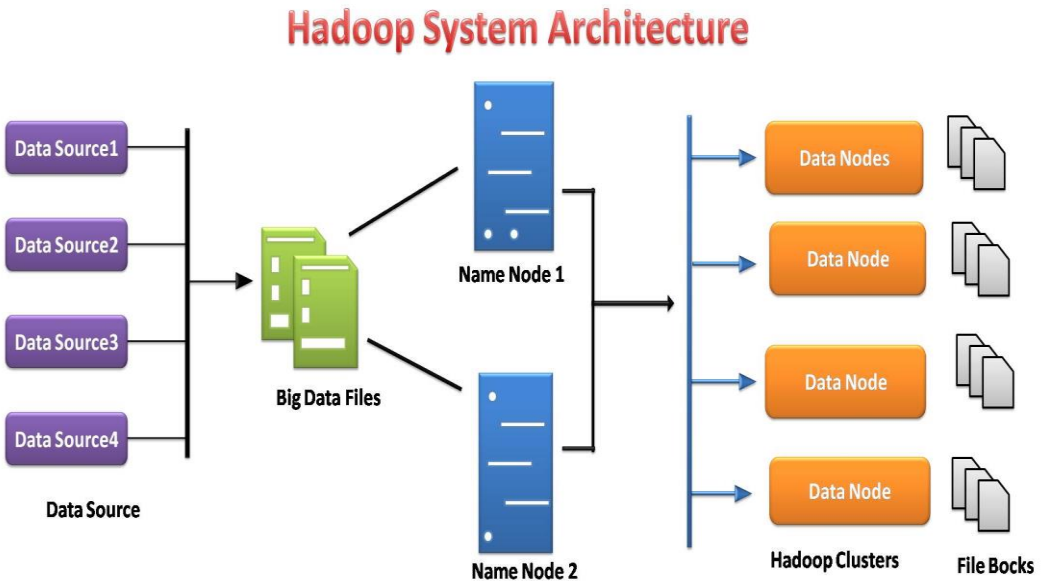
Ante este panorama, surge la necesidad de adoptar un **nuevo enfoque**.

Apache Hadoop surge como respuesta a esta necesidad, basando su modelo en **principios distribuidos**.

Almacenamiento distribuido (HDFS)

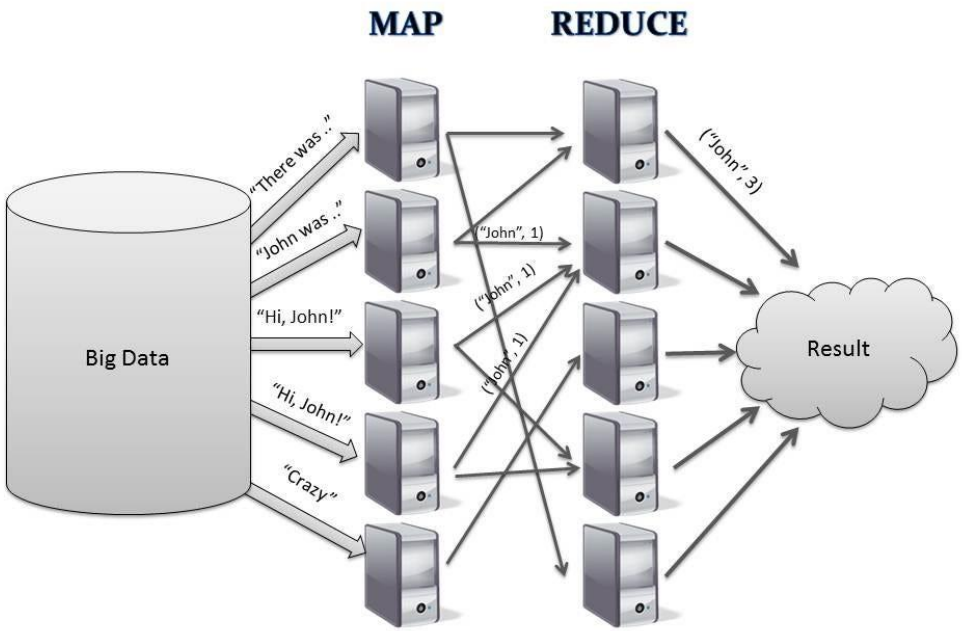
Los datos se dividen en bloques y se almacenan en múltiples nodos del clúster.

Se aprovecha la capacidad de múltiples máquinas en lugar de depender de un único servidor.



Ante este panorama, surge la necesidad de adoptar un **nuevo enfoque**.

Apache Hadoop surge como respuesta a esta necesidad, basando su modelo en **principios distribuidos**.



Procesamiento distribuido (MapReduce, Spark)

Las tareas se dividen y ejecutan en paralelo en los distintos nodos del clúster.

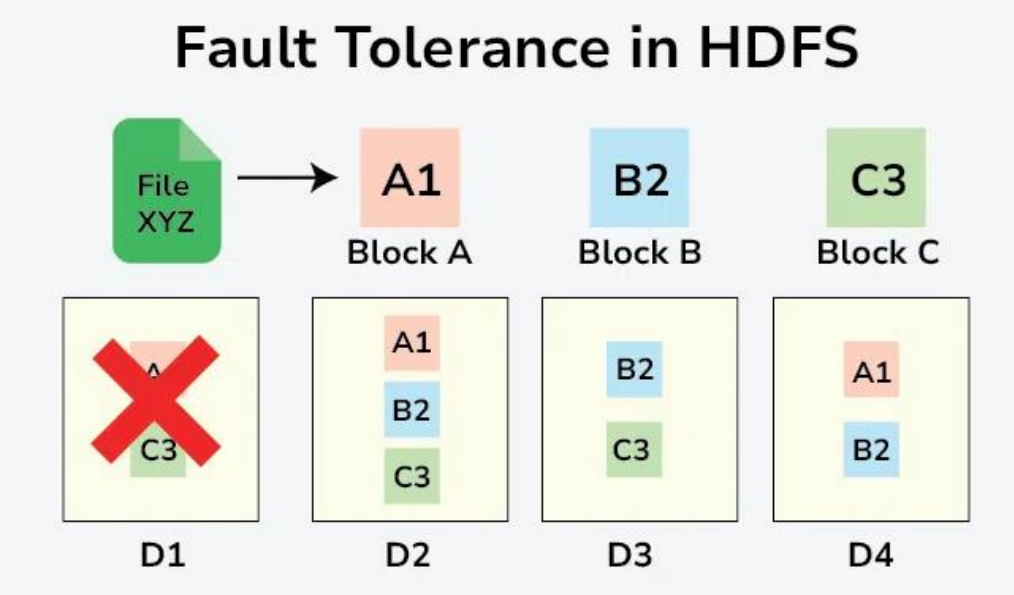
Se reducen enormemente los tiempos de procesamiento

Ante este panorama, surge la necesidad de adoptar un **nuevo enfoque**.

Apache Hadoop surge como respuesta a esta necesidad, basando su modelo en **principios distribuidos**.

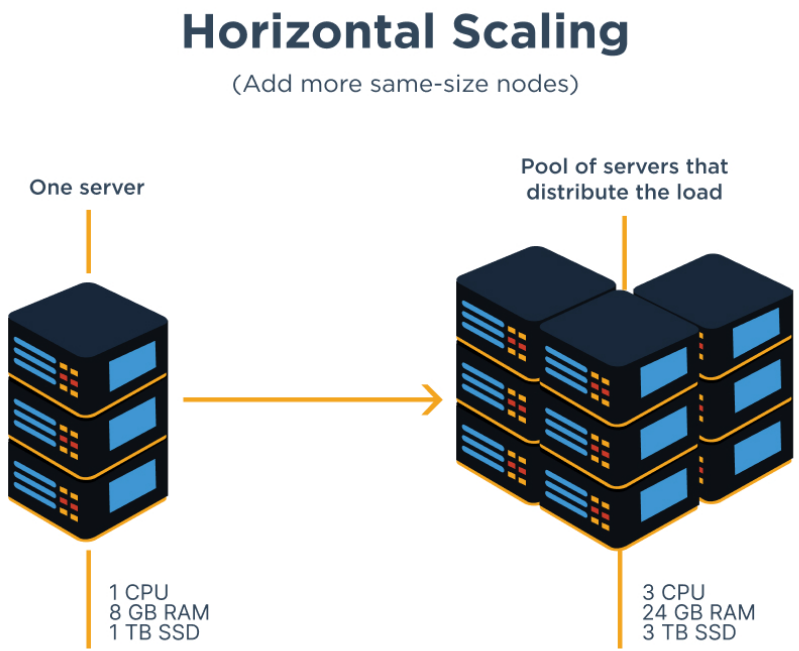
Tolerancia a fallos

Los sistemas distribuidos como Hadoop replican datos y pueden reintentar tareas automáticamente en caso de fallos, garantizando la **alta disponibilidad**



Ante este panorama, surge la necesidad de adoptar un **nuevo enfoque**.

Apache Hadoop surge como respuesta a esta necesidad, basando su modelo en **principios distribuidos**.

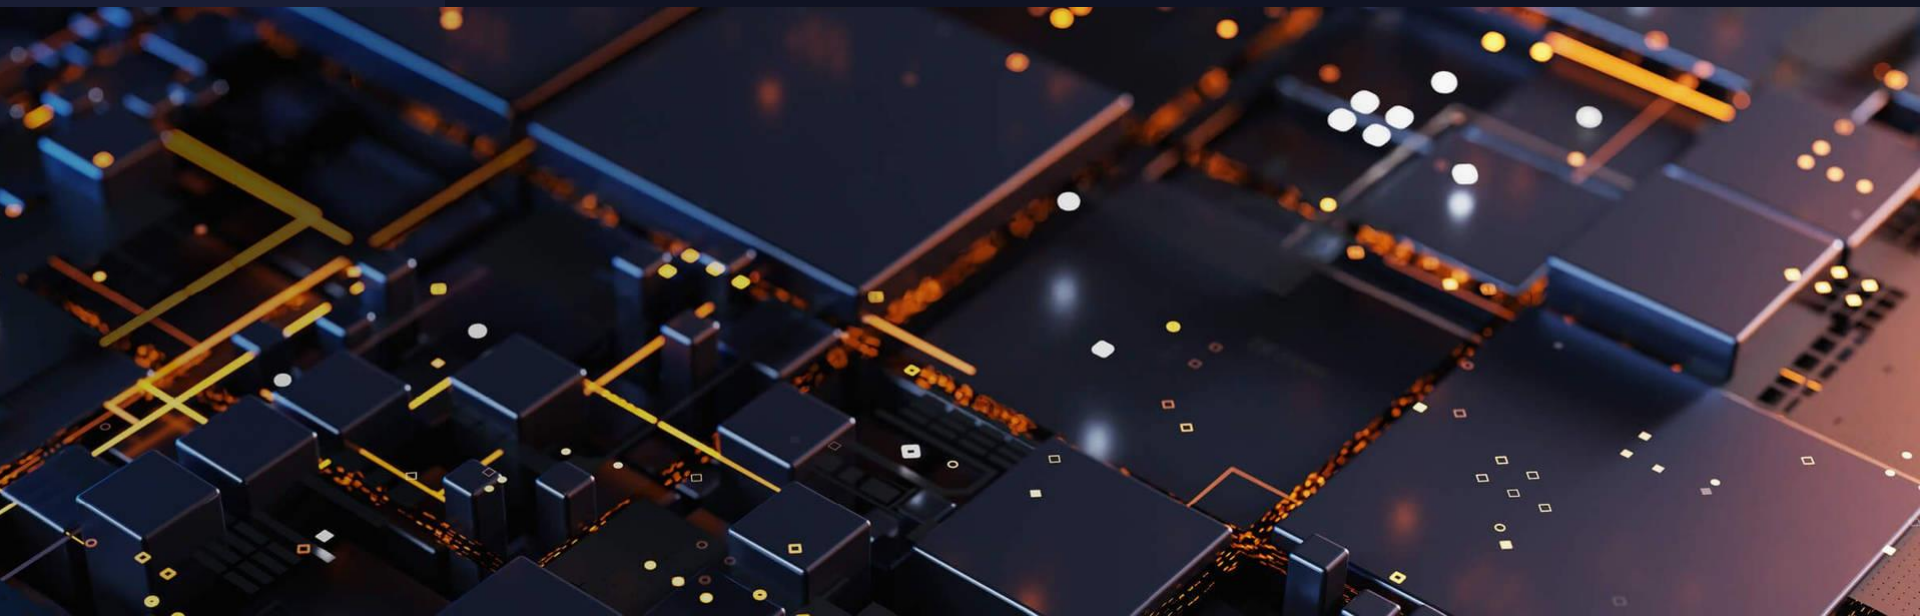


Escalabilidad horizontal

Es posible añadir más nodos al clúster para aumentar la capacidad de almacenamiento o procesamiento sin interrumpir el sistema.

2

APACHE HADOOP, ¿QUÉ ES?



¿QUÉ ES APACHE HADOOP?

Apache Hadoop es un framework de software de código abierto que permite el almacenamiento distribuido y el procesamiento paralelo de grandes volúmenes de datos utilizando clústeres de ordenadores convencionales.



¿QUÉ ES APACHE HADOOP?

Víctor J. González

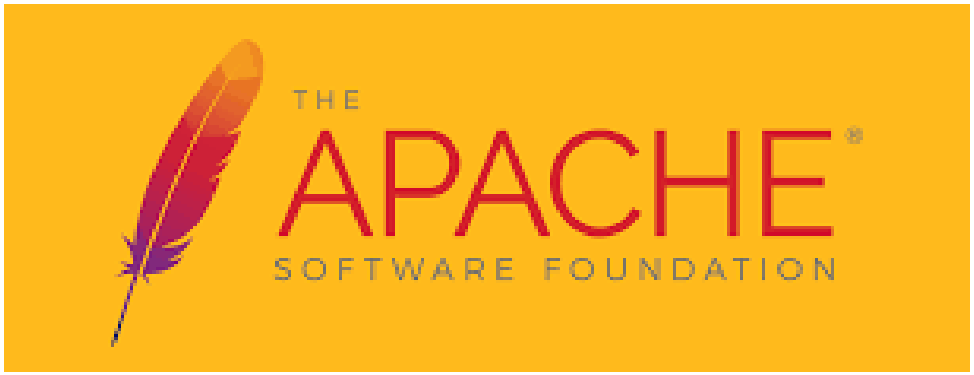
Apache Hadoop es un **framework de software** de código abierto que permite el almacenamiento distribuido y el procesamiento paralelo de grandes volúmenes de datos utilizando clústeres de ordenadores convencionales.

Framework de software: Hadoop es un marco de trabajo, es decir, un conjunto de librerías, servicios y herramientas ya preparados para que los desarrolladores o administradores puedan construir aplicaciones sin tener que hacerlo desde cero.

¿QUÉ ES APACHE HADOOP?

Apache Hadoop es un framework de software **de código abierto** que permite el almacenamiento distribuido y el procesamiento paralelo de grandes volúmenes de datos utilizando clústeres de ordenadores convencionales.

De código abierto: Hadoop pertenece a la Apache Software Foundation y está disponible mediante una licencia Open Source, de forma que cualquiera puede descargar, usar, modificar y redistribuir el código sin coste de licencias.

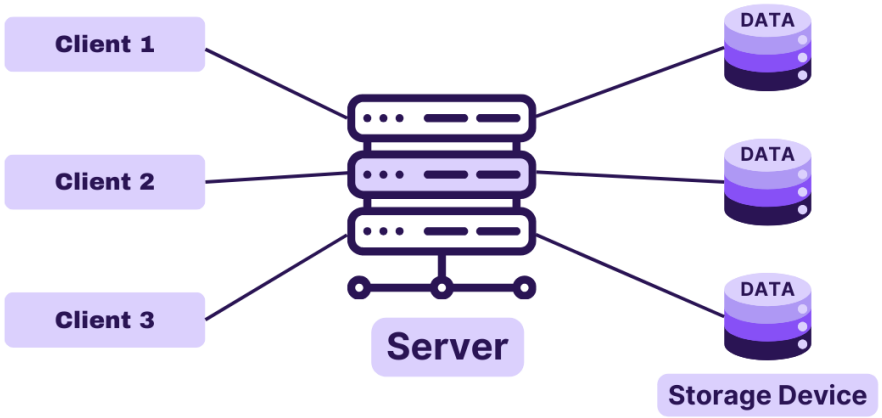


¿QUÉ ES APACHE HADOOP?

Víctor J. González

Apache Hadoop es un framework de software de código abierto que permite el **almacenamiento distribuido** y el procesamiento paralelo de grandes volúmenes de datos utilizando clústeres de ordenadores convencionales.

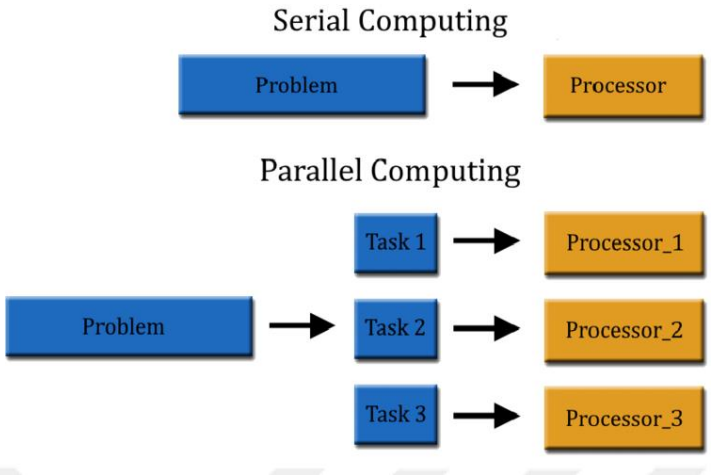
Almacenamiento distribuido: los datos no se guardan en un solo servidor, sino que se parten en bloques y se guardan en diferentes nodos del clúster.



¿QUÉ ES APACHE HADOOP?

Apache Hadoop es un framework de software de código abierto que permite el almacenamiento distribuido y el **procesamiento paralelo** de grandes volúmenes de datos utilizando clústeres de ordenadores convencionales.

Procesamiento paralelo: en lugar de que un único ordenador procese todos los datos secuencialmente, se divide el trabajo en muchas tareas que corren en paralelo en diferentes nodos.

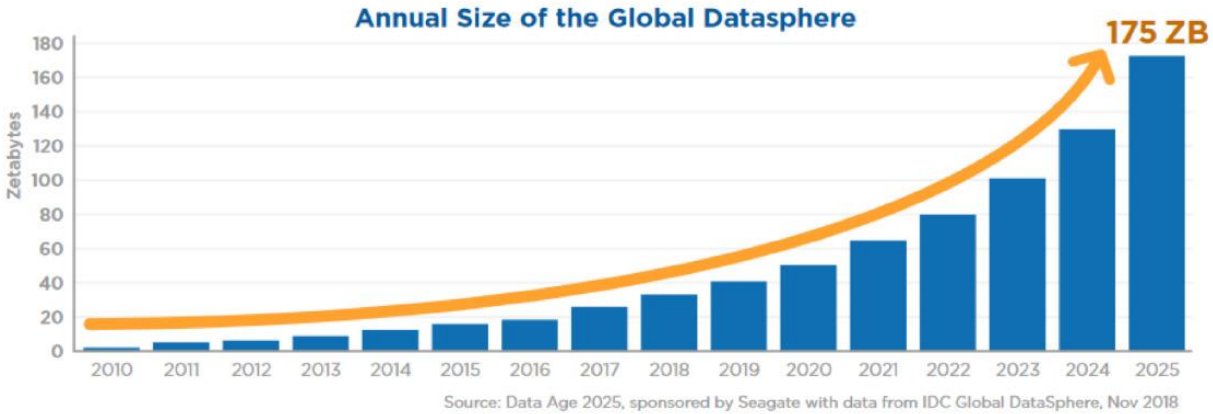


¿QUÉ ES APACHE HADOOP?

Víctor J. González

Apache Hadoop es un framework de software de código abierto que permite el almacenamiento distribuido y el procesamiento paralelo de **grandes volúmenes de datos** utilizando clústeres de ordenadores convencionales.

Grandes volúmenes de datos: Hadoop está diseñado para lo que llamamos Big Data, conjuntos de datos del orden de Terabytes o Exabytes que no pueden ser procesados con métodos tradicionales.

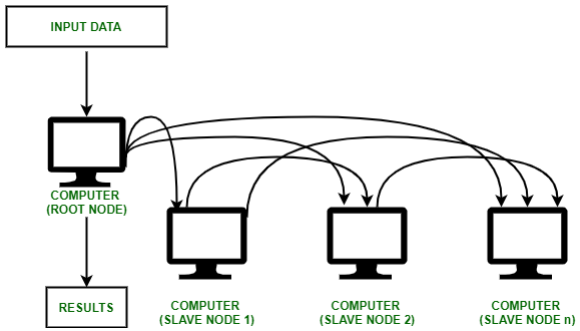


¿QUÉ ES APACHE HADOOP?

Víctor J. González

Apache Hadoop es un framework de software de código abierto que permite el almacenamiento distribuido y el procesamiento paralelo de grandes volúmenes de datos utilizando **clústeres de ordenadores convencionales**.

Clústeres de ordenadores convencionales: Hadoop trabaja sobre conjuntos de ordenadores conectados en red que trabajan como si fueran uno solo. Además, no requiere supercomputadoras, sino que se puede montar sobre hardware barato (*commodity hardware*) y aprovechar muchos nodos simples en lugar de unos pocos muy potentes.



¿QUÉ ES APACHE HADOOP?

Víctor J. González

Apache Hadoop **resuelve dos problemas clave** del Big Data:

Almacenar datos que no caben en un único servidor.

Procesar grandes cantidades de información de forma eficiente y tolerante a fallos

Para conseguir resolver estos dos problemas, Hadoop tiene **dos tecnologías fundamentales**.

COMPONENTES PRINCIPALES DE HADOOP

Víctor J. González

HDFS (Hadoop Distributed File System)

Sistema de archivos distribuido

Permite almacenar archivos de gran tamaño dividiéndolos en bloques y distribuyéndolos entre los nodos del clúster.

Ofrece alta disponibilidad gracias a la replicación de bloques

Diseñado para trabajar eficientemente con lecturas y escrituras secuenciales de archivos de gran tamaño.



YARN (Yet Another Resource Negotiator)

Es el sistema que gestiona los recursos del clúster y controla la ejecución de aplicaciones.

YARN permite múltiples motores de procesamiento que pueden compartir recursos dentro del mismo entorno.

YARN está disponible a partir de Hadoop 2.x



COMPONENTES PRINCIPALES DE HADOOP

Víctor J. González

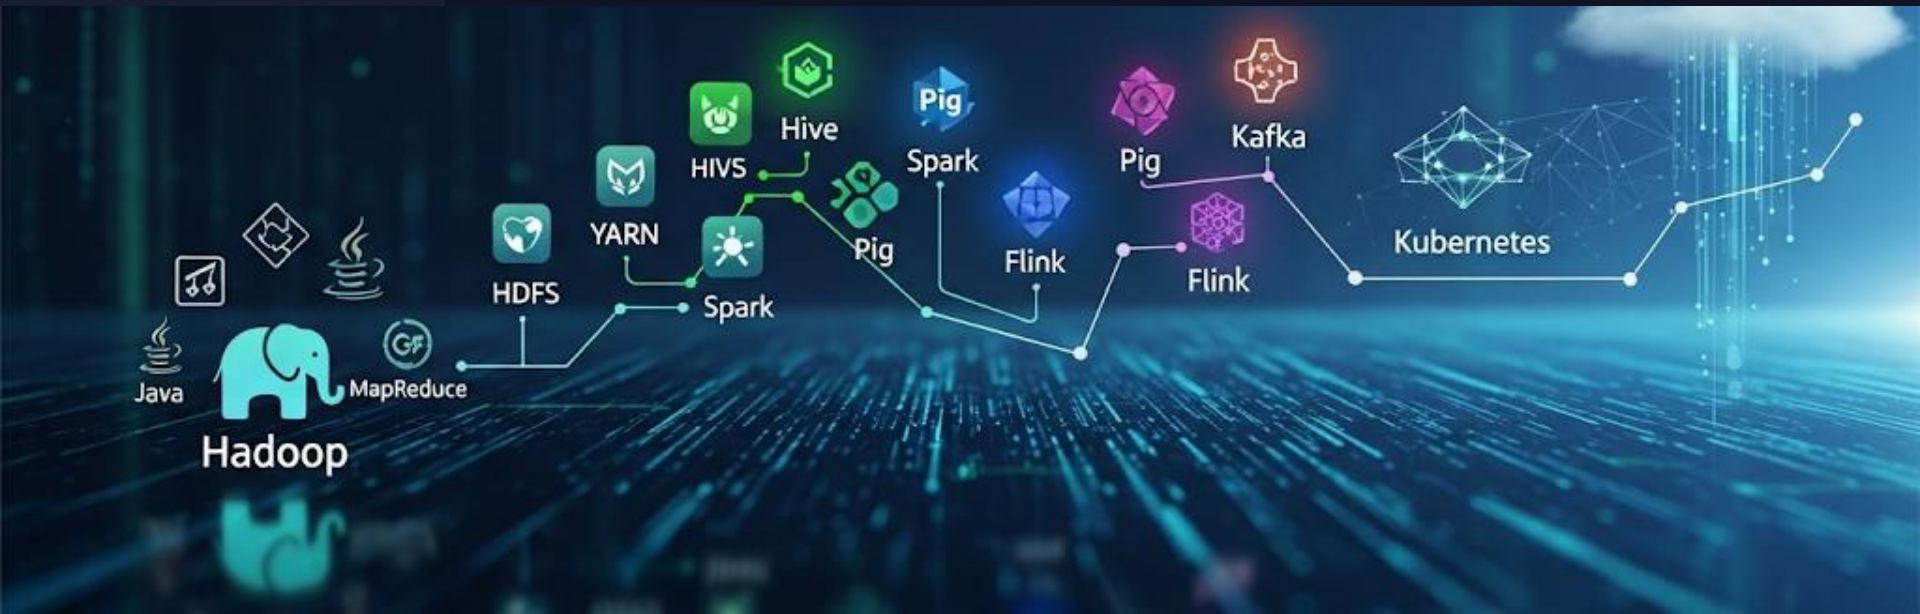
Aunque la base de Hadoop son HDFS y YARN, dispone de un enorme ecosistema con múltiples herramientas como:

- **MapReduce**: el motor de procesamiento por lotes que forma parte del diseño original de Hadoop.
- **Apache Hive**, **Apache Pig**: lenguajes de alto nivel para realizar consultas y transformaciones de datos.
- **Apache Spark**: motor de procesamiento distribuido en memoria que puede ejecutarse sobre Hadoop.
- **HBase, Oozie, Zookeeper**, entre otros.

CARACTERÍSTICAS DE HADOOP

ESCALABILIDAD	Puede crecer fácilmente añadiendo más nodos al clúster
TOLERANCIA A FALLOS	Los datos están replicados en distintos nodos para prevenir pérdidas por fallos de hardware
PORTABILIDAD	Al estar desarrollado íntegramente en Java, puede ejecutarse en múltiples plataformas
EFICIENCIA	Permite el procesamiento paralelo masivo de datos en bloques distribuidos
ECOSISTEMA EN EXPANSIÓN	Hay una gran comunidad y una amplia gama de herramientas complementarias

3 APACHE HADOOP, HISTORIA



HISTORIA DE HADOOP

Víctor J. González

La historia de Hadoop está ligada al nacimiento del Big Data.

Antes de Hadoop, procesas conjuntos de datos masivos a bajo coste era prácticamente imposible para la mayoría de las empresas.

La solución fue Hadoop, que **democratizó el análisis de datos a gran escala**.

Años 2000

A principios del 2000, Google vio la necesidad de buscar alguna tecnología que le permitiera indexar y procesar millones de páginas web

HISTORIA DE HADOOP

Víctor J. González

2003

En este año Google publica un artículo titulado "*The Google File System*" que detalla su diseño e implementación como sistema de ficheros distribuidos para el procesamiento de grandes cantidades de datos.

The Google File System

2004

Los ingenieros de Google, Jeffrey Dean y Sanjay Ghemawat publican un artículo titulado "*MapReduce: simplified data processing on large clusters*"



2004

Simultáneamente, dos ingenieros de Yahoo!, Doug Cutting y Mike Cafarella, que estaban trabajando en el proyecto de búsqueda **Nutch**, se encontraron los mismos problemas de escalabilidad, por lo que decidieron implementar una **versión de código abierto** de estas tecnologías.



2005

El proyecto Nutch migró a lo que se llamó **Hadoop**, un nombre que Doug Cutting le puso en honor al elefante de juguete de su hijo



HISTORIA DE HADOOP

Víctor J. González

2006

Hadoop se separa de Nutch para convertirse en un **proyecto independiente** de **Apache Software Foundation**, con Yahoo! como principal patrocinador.



2012

Llega **Hadoop 2**, que supone un punto de inflexión. Se introduce **YARN**, un gestor de recursos que desacopló la gestión de recursos del modelo de procesamiento.



HISTORIA DE HADOOP

Víctor J. González

2012

Con Hadoop 2, MapReduce pasa a ser una aplicación más. Esto permitió que otras tecnologías de procesamiento, como **Apache Spark** puedan coexistir en el mismo clúster de Hadoop.



Actualidad

Actualmente, Hadoop ya no es solo HDFS y MapReduce, sino que es un vasto **ecosistema** de proyectos de código abierto que trabajan en conjunto para resolver diferentes problemas de Big Data

ECOSISTEMA DE HADOOP

Víctor J. González

En la actualidad, el ecosistema asociado a Hadoop es enorme, con todo tipo de aplicaciones orientadas al trabajo con grandes cantidades de datos desde cualquier perspectiva.





Apache Hive

Herramienta de data warehousing que permite **consultar y analizar** grandes volúmenes de datos almacenados en HDFS usando un lenguaje similar a SQL (**HiveQL**)



Apache Pig

Plataforma de alto nivel para crear programas de MapReduce utilizando un lenguaje de scripting llamado **Pig Latin**. Simplifica la escritura de tareas complejas de procesamiento de datos



Apache Spark

Motor de **procesamiento de datos en memoria** que permite realizar análisis de datos en tiempo real, procesamiento por lotes y *machine learning*. Compatible con lenguajes como Scala, Java, Python o R



Apache HBase

Base de datos **NoSQL** distribuida y escalable que se ejecuta sobre HDFS



Apache Kafka

Plataforma de *streaming* distribuida para la **ingesta y procesamiento de flujos de datos en tiempo real**. Ideal para aplicaciones de mensajería y procesamiento de eventos



Apache Flume

Herramienta para la recolección, agregación y movimiento de grandes cantidades de **datos de logs** hacia HDFS



Apache Zookeeper

Servicio centralizado para mantener la **configuración, sincronización y coordinación de servicios distribuidos**. Es esencial para la gestión de clústeres y la alta disponibilidad

Apache Scoop

Herramienta para **transferir datos** entre Hadoop y bases de datos relacionales (MySQL, Oracle)

Apache Oozie

Sistema de programación de **flujos de trabajo** (*workflow*) para gestionar tareas de Hadoop. Permite orquestar tareas complejas que involucran múltiples herramientas del ecosistema



Apache Mahout

Biblioteca de ***machine learning*** escalable para realizar tareas como clasificación, recomendación y clasificación



Apache Storm

Sistema de **procesamiento de flujos de datos** en tiempo real



Apache NiFi

Herramienta para **automatizar el flujo de datos** entre sistemas mediante una interfaz gráfica



Apache Tez

Framework para ejecutar tareas de **procesamiento de datos** de manera más eficiente que MapReduce.



Apache Drill

Motor de consultas SQL distribuido para **datos no estructurados y semiestructurados**. Permite consultar datos en formato JSON, Parquet o CSV sin necesidad de un esquema predefinido



Apache Atlas

Herramienta de gobierno y metadatos para **gestionar y rastrear el linaje de los datos** en Hadoop



Apache Zeppelin

Notebook interactivo para realizar **análisis de datos, visualizaciones y colaboración**. Compatible con múltiples lenguajes (Scala, Python, R) y herramientas (Spark, Hive)



Apache Ranger

Framework de **seguridad** para gestionar políticas de acceso y auditoría en Hadoop



Apache Ambari

Herramienta de **gestión y monitorización de clústeres** Hadoop que simplifica la instalación, configuración y mantenimiento del clúster



Apache Kylin

Motor de OLAP (Procesamiento Analítico en Línea) para Hadoop.



Apache Phoenix

Capa SQL sobre HBase para realizar **consultas en tiempo real**.
Combina la escalabilidad de HBase con la facilidad de uso de SQL



Apache Flink

Framework de **procesamiento de flujos de datos en tiempo real** y por lotes, ideal para aplicaciones de streaming.



Apache Knox

Puerta de enlace (*gateway*) para proporcionar **acceso seguro** a los servicios de Hadoop



Apache Superset

Herramienta de visualización y exploración de datos que permite crear ***dashboards* interactivos y gráficos** a partir de datos almacenados en Hadoop

4 APACHE HADOOP, PROBLEMAS QUE RESUELVE



PROBLEMAS QUE RESUELVE HADOOP

Víctor J. González

Los sistemas tradicionales de almacenamiento y procesamiento se han quedado cortos frente al **crecimiento masivo**, la **variedad** y la **velocidad** con la que se generan los datos.

Hadoop es la solución a múltiples desafíos:

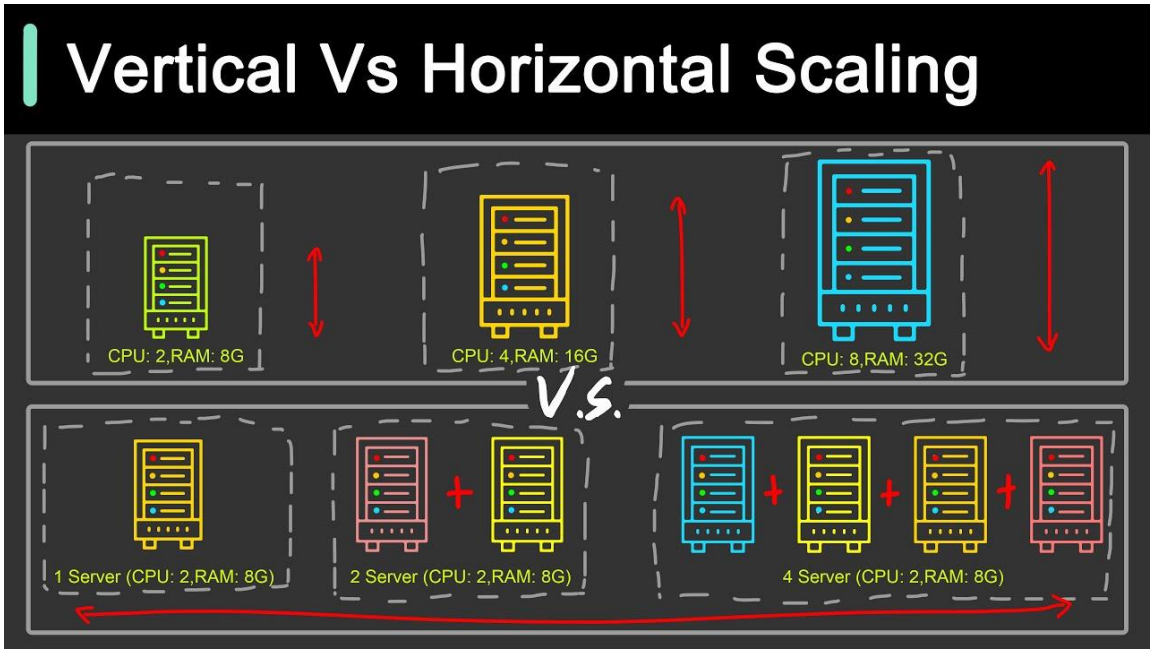
- Escalabilidad horizontal
- Almacenamiento distribuido
- Procesamiento paralelo
- Tolerancia a fallos
- Flexibilidad en el tratamiento de datos
- Coste

ESCALABILIDAD HORIZONTAL

Las bases de datos tradicionales escalan de forma **vertical** (más recursos a una única máquina).

Hadoop escala **horizontalmente**, agregando más nodos económicos al clúster.

Permite cantidades masivas de datos sin invertir en hardware especializado y costoso

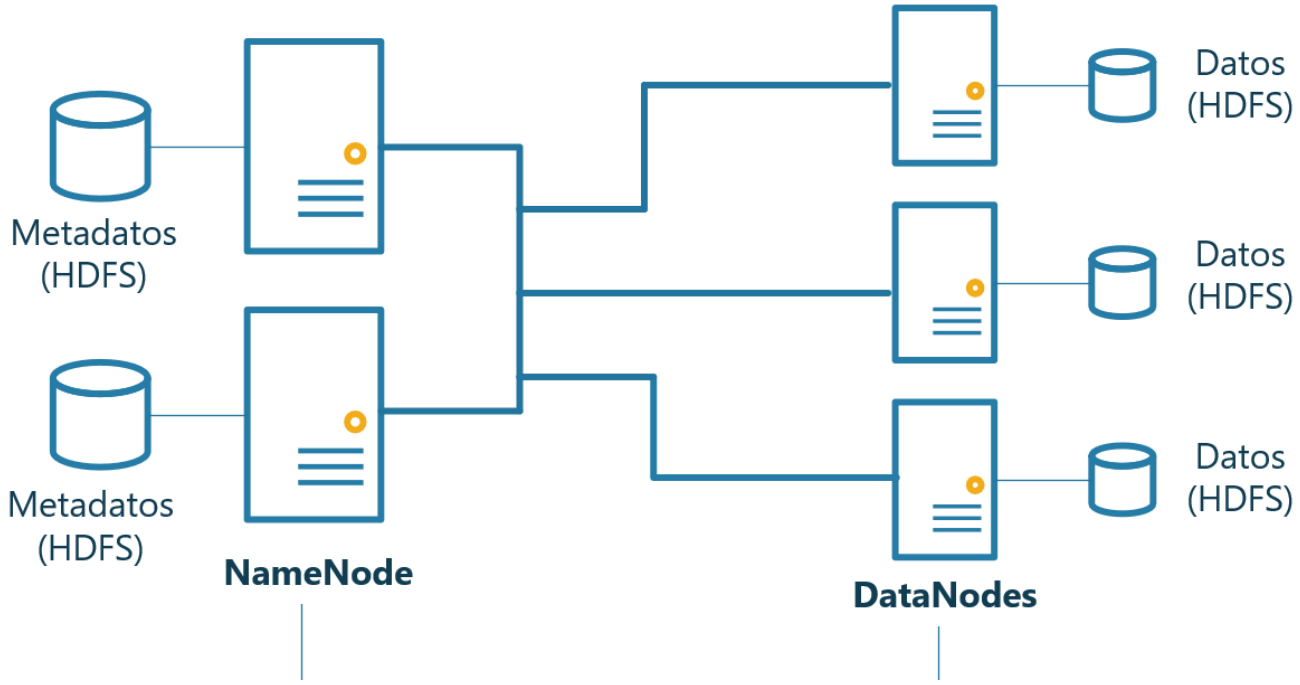


ALMACENAMIENTO DISTRIBUIDO

Otro desafío es el almacenamiento de grandes cantidades de datos.

HDFS distribuye los archivos en bloques y los reparte entre diferentes nodos.

Además, cada bloque se replica automáticamente, garantizando disponibilidad e integridad.

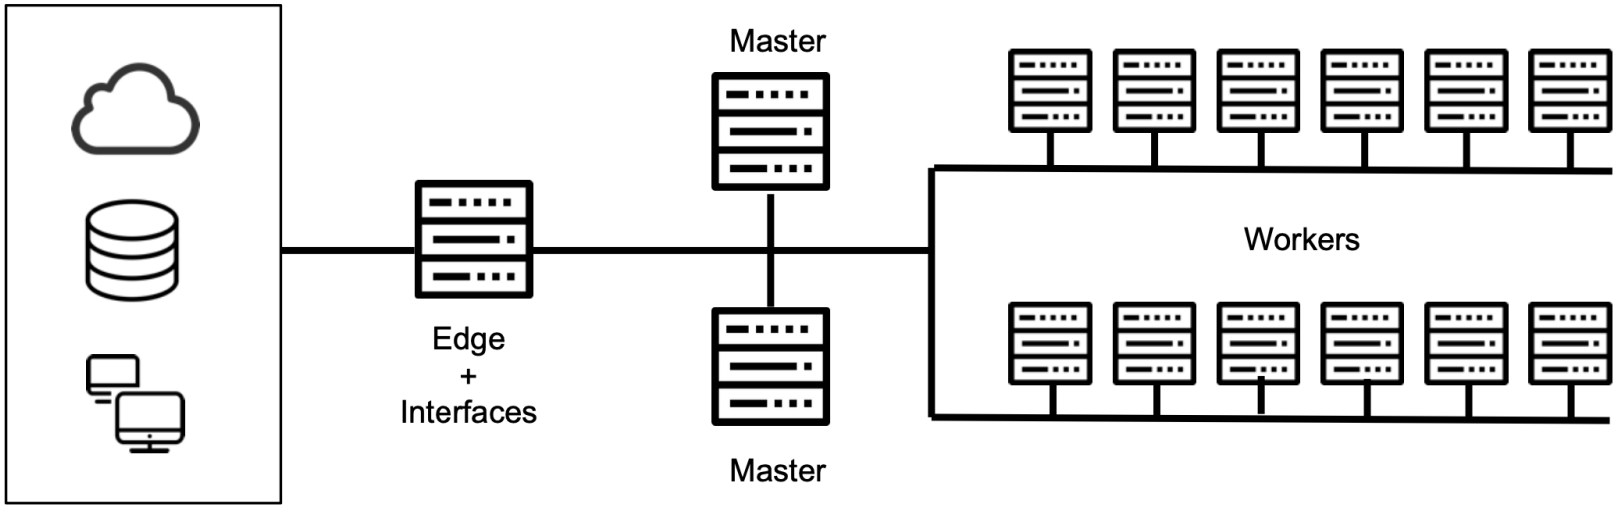


PROCESAMIENTO PARALELO

Procesar grandes cantidades de datos eficientemente es otro desafío.

Hadoop permite procesamiento paralelo masivo mediate modelos como MapReduce o Spark.

Las tareas se distribuyen y ejecutan simultáneamente en múltiples nodos.

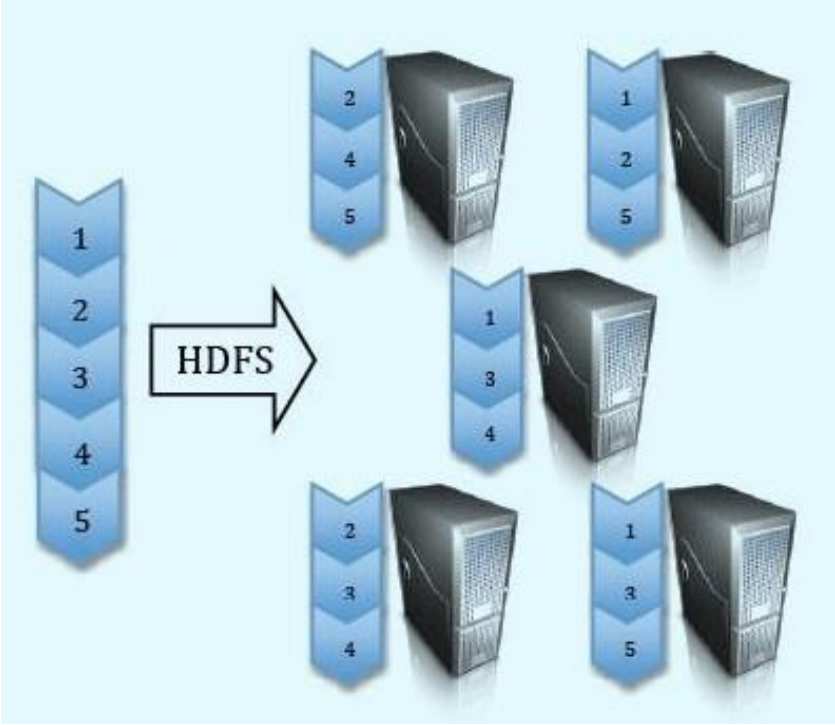


TOLERANCIA A FALLOS

En sistemas distribuidos en habitual que algunos nodos fallen.

Hadoop está diseñado con una fuerte tolerancia a fallos gracias a la **replicación de bloques** y a la **replanificación automática de tareas**.

Esto evita la realización de backups y garantiza alta disponibilidad



FLEXIBILIDAD EN EL TRATAMIENTO DE DATOS

Los sistemas estructurados exigen **datos estructurados**.

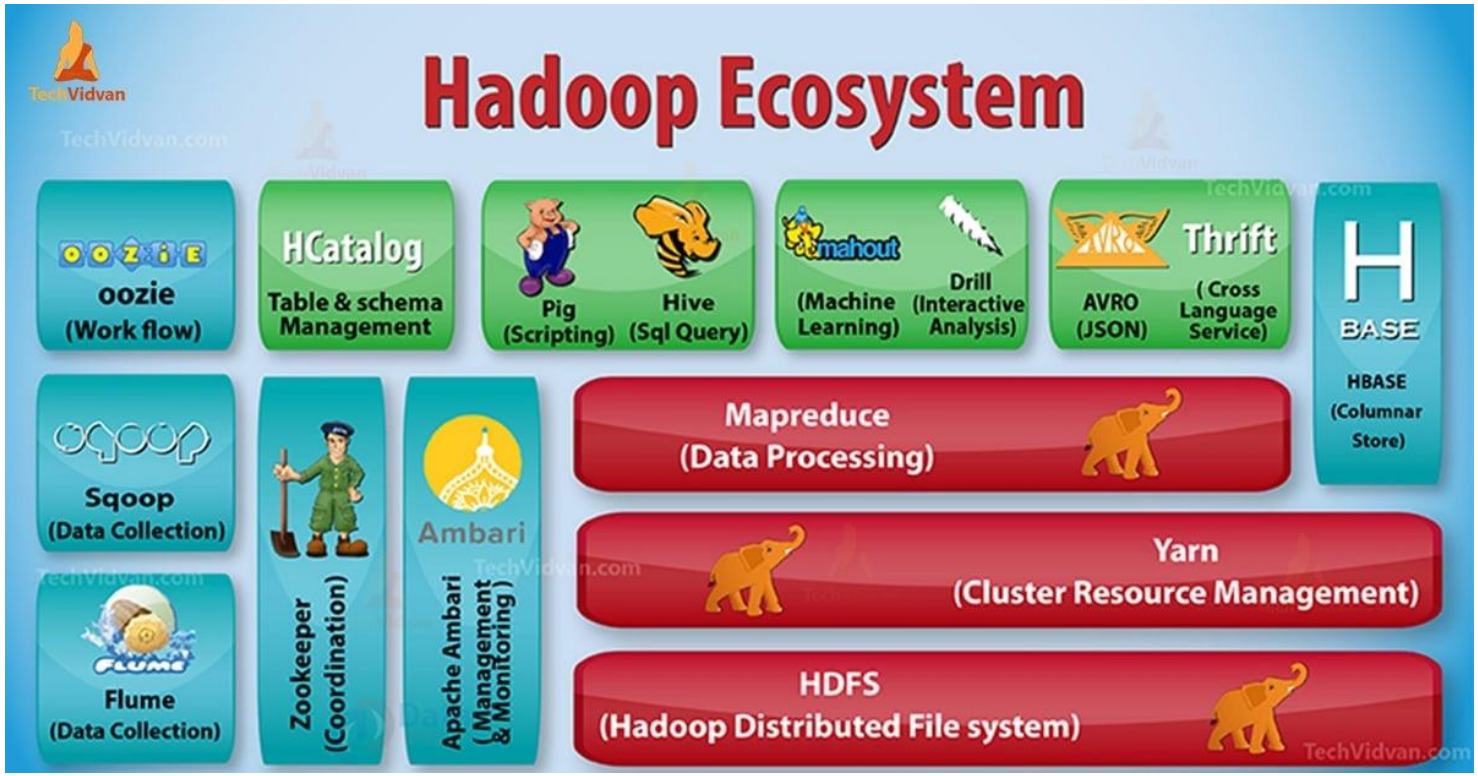
Hadoop permite trabajar con datos estructurados, semi-estructurados y no estructurados, como logs de servidores, archivos JSON, XML, imágenes, vídeos o datos en texto plano.



COSTE

Hadoop es software libre y se puede ejecutar sobre hardware convencional, lo que permite reducir costes frente a soluciones propietarias.

Esto democratiza el acceso al procesamiento de grandes cantidades de datos.

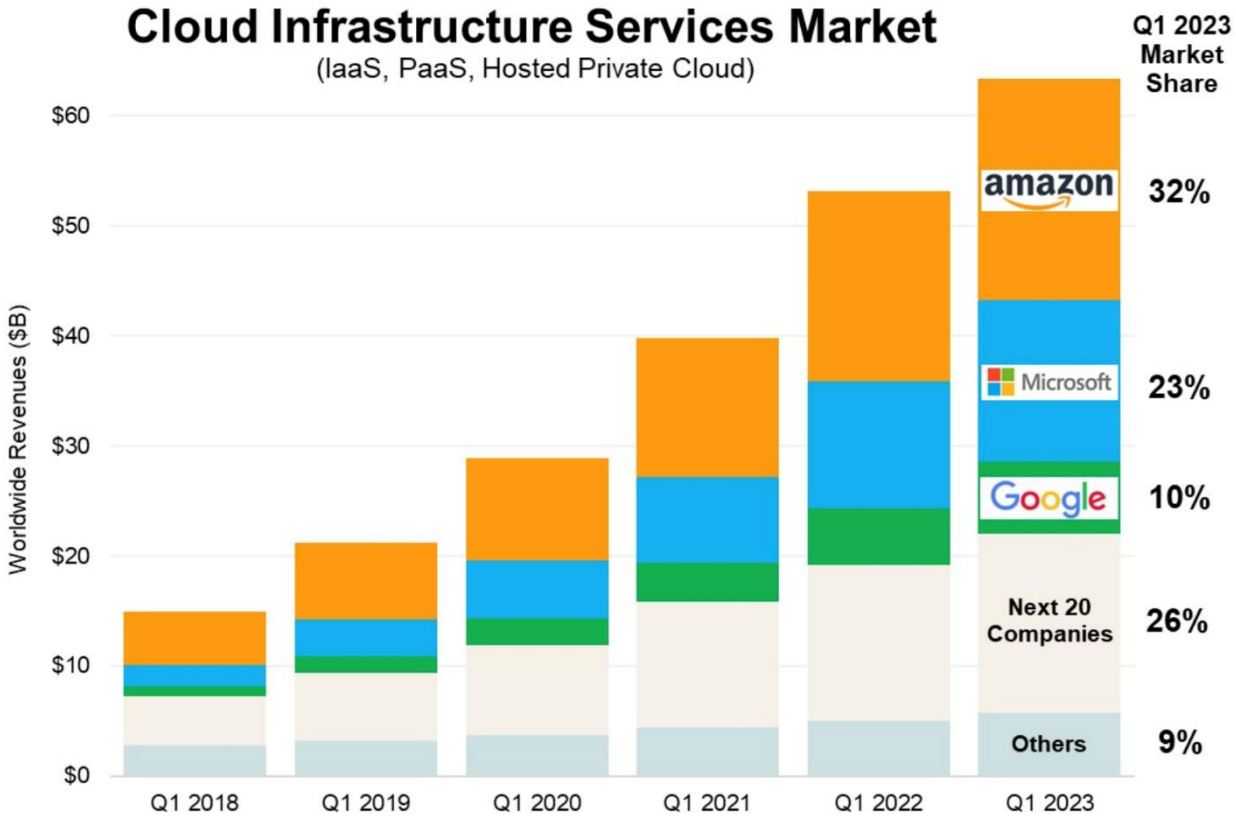


5 AMAZON WEB SERVICES, ¿QUÉ ES?

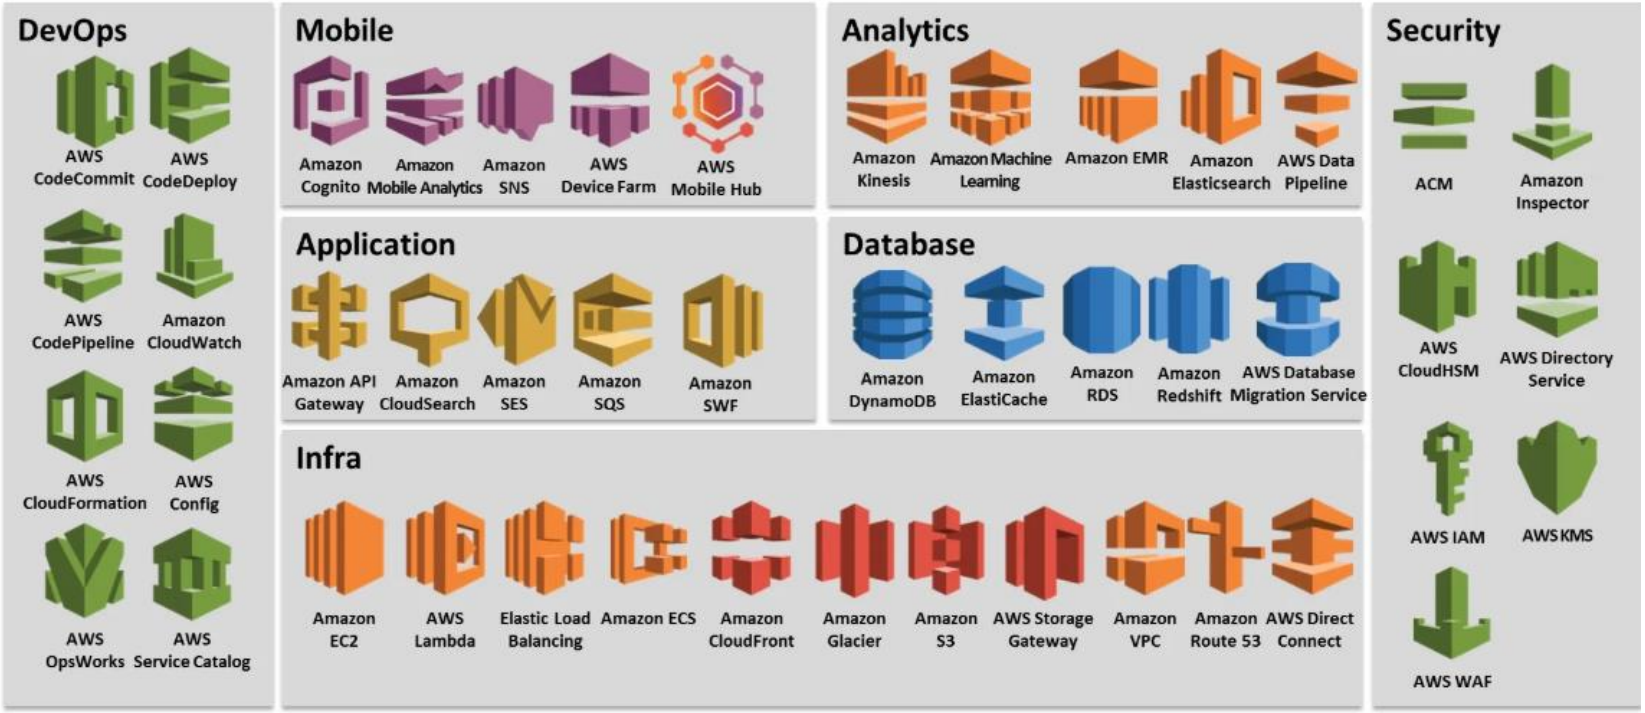


Amazon AWS es la plataforma de computación en la nube más adoptada y completa del mundo.

Básicamente es una **infraestructura masiva de centros de datos** repartidos por todo el globo que Amazon alquila a empresas y particulares.



Pero en realidad, AWS no es solo un conjunto de servidores, sino un **ecosistema de servicios gestionados** que permiten procesar petabytes de información sin necesidad de realizar ninguna inversión en hardware físico.

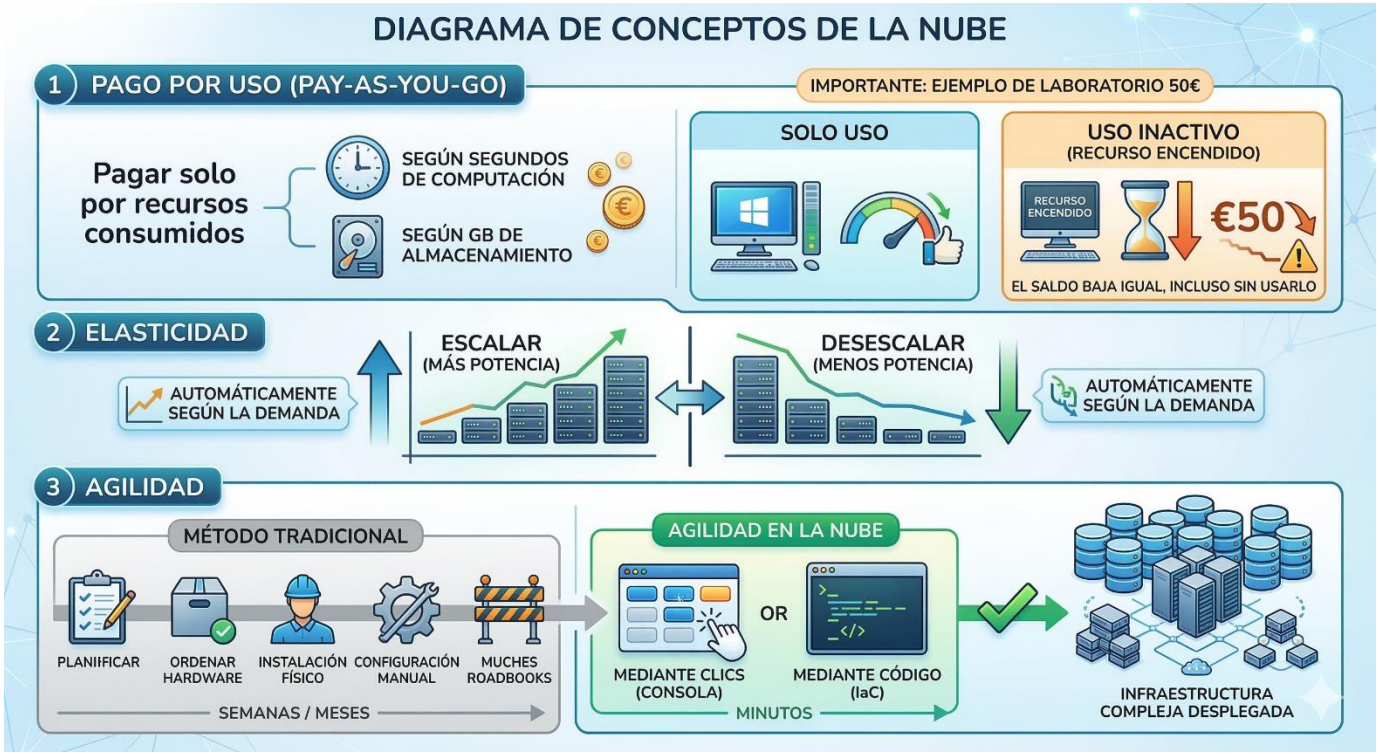


PILARES DEL MODELO CLOUD

Víctor J. González

Al trabajar con AWS, hay **tres conceptos** que rigen la plataforma:

- **Pago por uso**: solo se paga por los recursos que se consumen.
- **Elasticidad**: puede escalar o desescalar automáticamente
- **Agilidad**: despliegue rápido deinfraestructuras complejas (como un clúster de bases de datos) en cuestión de minutos mediante clicks o código.



INFRAESTRUCTURA GLOBAL

Víctor J. González

Amazon AWS se organiza físicamente para garantizar que los datos estén cerca del usuario, por lo que debemos conocer estos conceptos:

Regiones

Son áreas geográficas aisladas en el mundo.

Cada región es independiente por motivos de latencia y leyes de protección de datos.

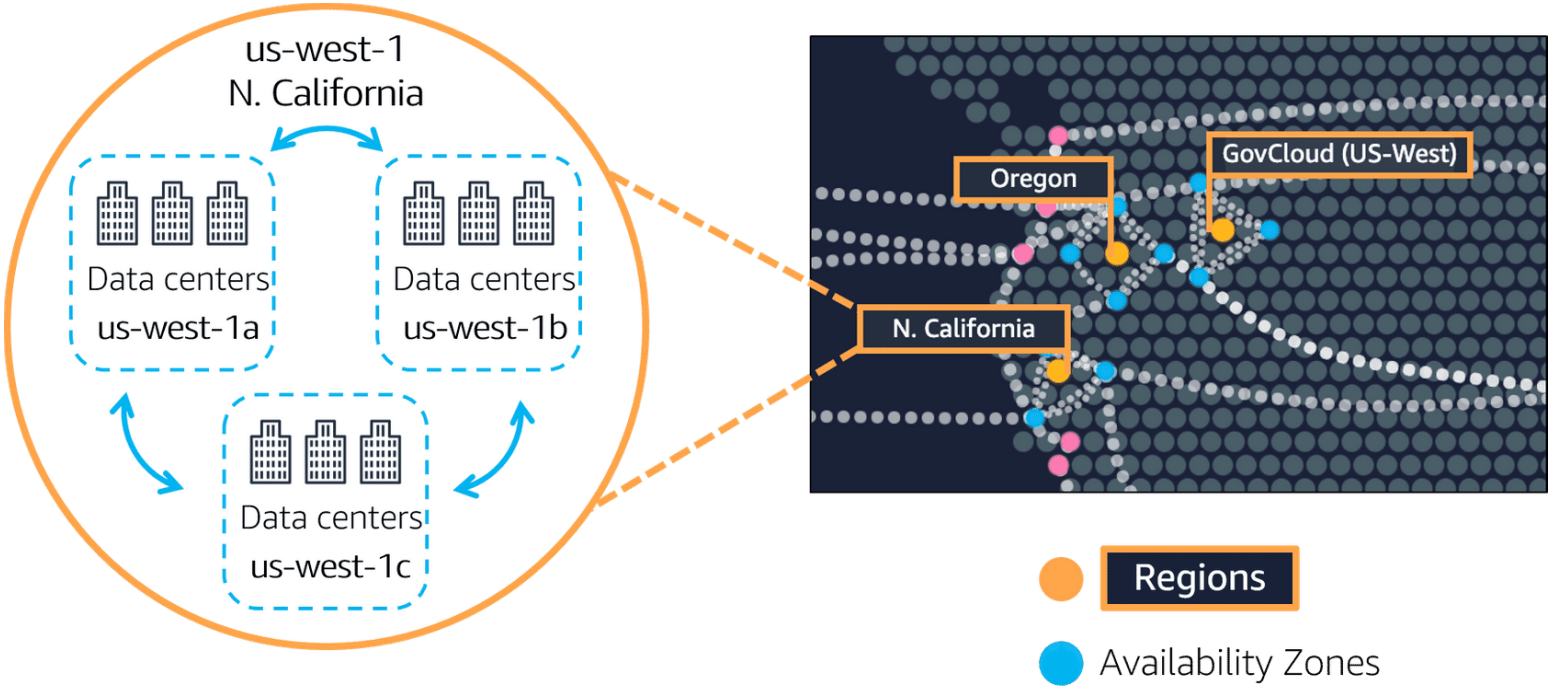


Zonas de disponibilidad

Dentro de cada región hay varias zonas de disponibilidad (AZ)

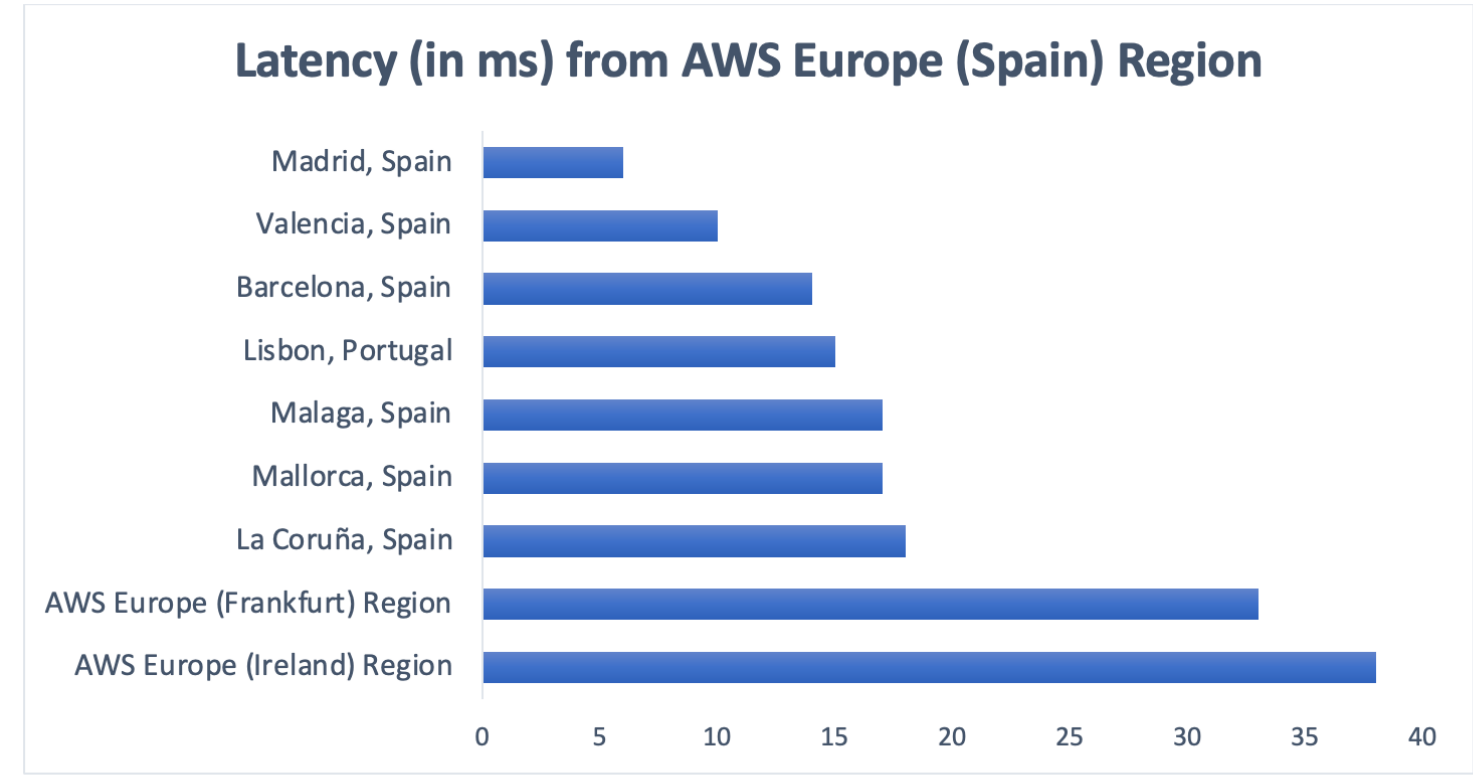
Una AZ es uno o más centros de datos físicos, separados por kilómetros, pero conectados por fibra de alta velocidad.

Si queremos alta disponibilidad debemos replicar nuestros datos en 2 o más AZs.



Puntos de presencia

Centros más pequeños repartidos por todo el mundo que sirven para cachear contenido y reducir la latencia de acceso.



SERVICIOS GESTIONADOS Y NO GESTIONADOS

Víctor J. González

El **Modelo de Responsabilidad Compartida** es el concepto más importante para la seguridad y el cumplimiento legal.

La responsabilidad se divide en dos:

- **Seguridad DE la nube**: Amazon se encarga de proteger la infraestructura física (servidores, red, centro de datos) y el software que hace que la nube funcione.
- **Seguridad EN la nube**: el usuario es responsable de lo que ponga dentro. Esto incluye:
  - Configurar quien tiene acceso (IAM)
  - Cifrar los datos en S3
  - Mantener actualizados los sistemas operativos de las MVs (EC2)

6 HISTORIA DE AMAZON WEB SERVICES



HISTORIA DE AMAZON WEB SERVICES

Víctor J. González

Amazon (originalmente llamada Cadabra) fue fundada en 1994 por Jeff Bezos en Seattle e inicialmente se dedicaba únicamente a la venta de libros.



HISTORIA DE AMAZON WEB SERVICES

Víctor J. González

A principios de la década de 2000, ya era un gigante electrónico en pleno crecimiento, pero tenía un grave problema operativo: **su infraestructura tecnológica no escalaba al ritmo de su negocio**.

Problema	Cada nuevo proyecto requería **diseñar todo desde cero** (bases de datos, servidores, almacenamiento, …)
Solución	Reformularon por completo la infraestructura interna **Desacoplaron** los equipos de las aplicaciones Todas las comunicaciones se realizaban exclusivamente a través de **APIs (Application Programming Services)** bien documentadas.

HISTORIA DE AMAZON WEB SERVICES

Víctor J. González

Una vez realizado este cambio de paradigma, se dieron cuenta de dos cosas:

- Se habían vuelto expertos en operar una **infraestructura distribuida** a escala masiva y eficiente.
- **Todas las empresas del mundo tenían el mismo problema** que habían tenido ellos: gastaban demasiado tiempo y dinero en gestionar la infraestructura en lugar de centrarse en el modelo de negocio.

En 2006 se lanzó oficialmente AWS. Su idea: **convertir la infraestructura informática en un servicio público donde cualquiera pudiera acceder a potencia de cómputo y almacenamiento pagando únicamente por lo que consumiera.**

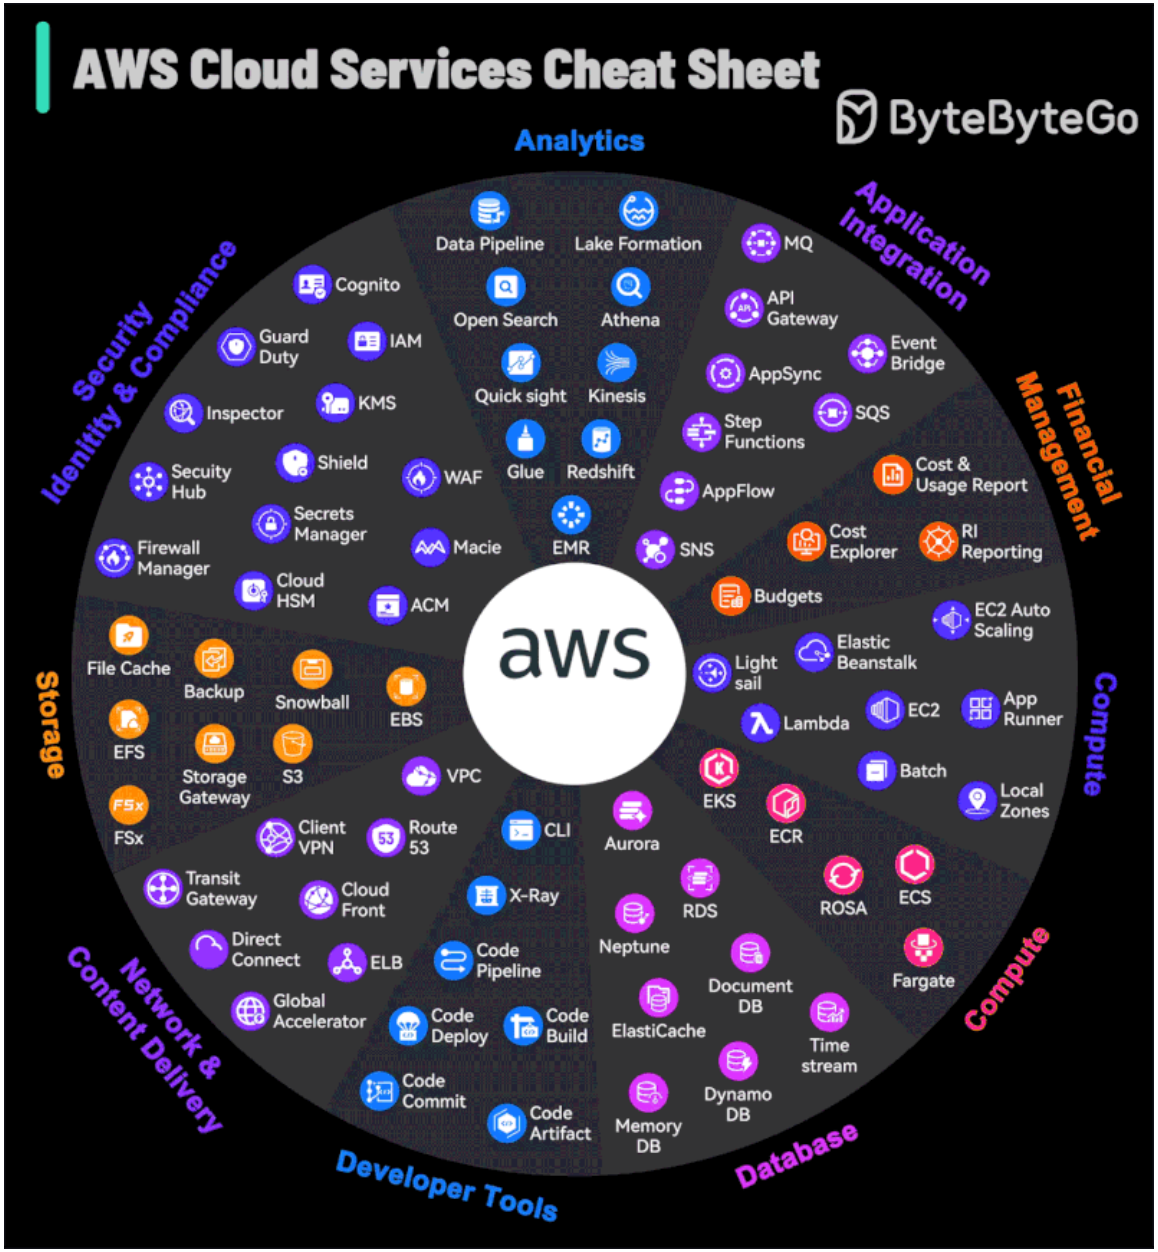


HISTORIA DE AMAZON WEB SERVICES

Víctor J. González

Actualmente, AWS dispone de **más de 200 servicios** que abarcan una amplia variedad de tecnologías:

- Computación
- Almacenamiento
- Bases de datos
- Redes
- Inteligencia Artificial
- Machine Learning
- IoT
- …

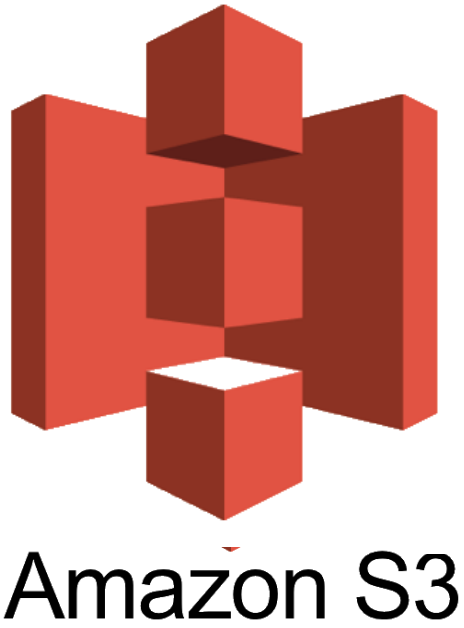


SERVICIOS RELACIONADOS CON BIG DATA

Víctor J. González

En el **ámbito del Big Data**, podemos destacar los siguientes servicios:

- Amazon S3 (Simple Storage Service)
- Amazon EC2 (Elastic Cloud Compute)
- EMR (Elastic Map Reduce)
- DynamoDB
- Redshift
- Amazon Lambda
- Amazon Athena
- Amazon Glue



S3 (Simple Storage Service)

- Primer servicio comercializado por AWS (2006) y supuso una revolución absoluta.
- Introdujo el concepto de **almacenamiento de objetos** (frente al almacenamiento tradicional en bloques o sistemas de archivos).
- Almacenamiento virtualmente infinito, de bajo coste y con una durabilidad del 99.999999999% (11 nueves).
- Permitía almacenar datos estructurados y no estructurados, sentando las bases de lo que hoy conocemos como **Data Lakes (Lagos de Datos)**, desvinculando por primera vez el almacenamiento del cómputo.



EC2 (Elastic Cloud Compute)

- Meses después de S3, llegó EC2, que permitía a los usuarios **alquilar máquinas virtuales** (instancias) en cuestión de minutos.
- Variedad de **tipos de instancias** (tamaño de RAM, número de cores, con GPUs, …)
- Capacidad de levantar miles de nodos de computación para procesar **cargas de trabajo masivas** de forma temporal.
- Permite aumentar o disminuir el número de servidores de forma automática para responder a picos de tráfico (**Auto Scaling**)



EMR (Elastic Map Reduce)

- Servicio gestionado que permite **desplegar clústeres de Hadoop de forma automatizada** sobre instancias EC2 usando S3 como almacenamiento.
- Democratizó el acceso al paradigma MapReduce, ya que permite levantar clústeres de para procesar los datos durante unas horas y luego destruirlos por muy poco costo.



DynamoDB

- En 2012 Amazon detectó la necesidad de gestionar bases de datos a escala en Internet
- **DynamoDB** es una base de datos NoSQL clave-valor gestionada de latencia de milisegundos a cualquier escala.
- A diferencia de las BBDD relacionales, **distribuye los datos en particiones físicas** de forma automática utilizando una **clave de partición**.
- No requiere configuración de servidores, permitiendo **escalarla horizontalmente** de forma ilimitada.



Amazon Redshift

- Amazon Redshift es una **base de datos columnar**
- Optimizada para **operaciones OLAP** (Online Analytical Processing) y análisis mediante SQL estándar. Esto son operaciones complejas que agregan y analizan miles de millones de filas a la vez.
- Las consultas se dividen y ejecutan en paralelo a través de un clúster de nodos.



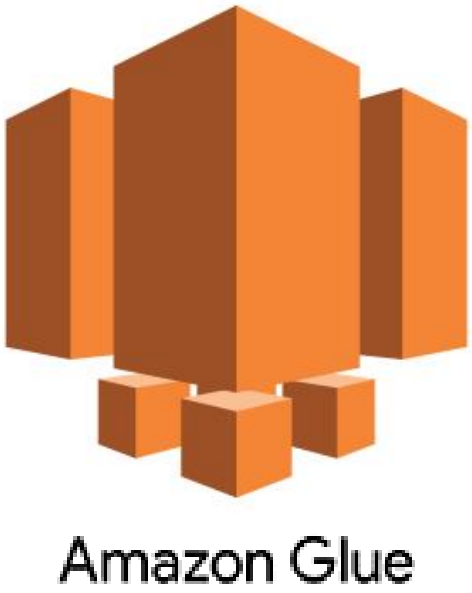
Amazon Lambda

- Es un servicio de computación **serverless** de tipo **Faas (Function as a Service)**. Permite ejecutar código sin necesidad de aprovisionar, configurar y administrar servidores.
- Simplemente hay que escribir código (Python, Node.js, Java, …), se vincula con un evento y **se ejecutará automáticamente cuando tenga lugar el evento**. Solo se paga por los milisegundos exactos de procesamiento.
- En Big Data es útil para procesamiento en tiempo real de flujos ligeros, validación y limpieza de datos entrantes y automatización de procesos en el pipeline de datos.



Amazon Athena

- Athena es un **motor de consultas interactivo y serverless** que permite lanzar consultas SQL sobre **datos almacenados en S3**
- Los datos sobre los que se realizan las consultas pueden estar en **múltiples formatos** (CSV, JSON, Parquet, ORC, …)
- Evita tener que desplegar un clúster Hadoop o Spark para hacer consultas exploratorias.
- Permite explorar el contenido de un Data Lake de forma rápida y barata.



AWS Glue

- Es un servicio de integración de datos totalmente administrado y serverless que facilita la **preparación, el movimiento y la transformación de datos (ETL)**
- Incluye varias herramientas:
  - **AWS Glue Data Catalog**: catálogo centralizado que guarda los **metadatos** de los datos (donde están, qué columnas y tipos de datos tienen)
  - **AWS Glue Crawlers**: programas automatizados que escanean orígenes de datos, deducen automáticamente su esquema y rellenan el Data Catalog.
  - **ETL Jobs**: tareas de procesamiento de datos masivos. Basado en Apache Spark.

7 PREPARACIÓN DEL ENTORNO



7 PREPARACIÓN DEL ENTORNO

7.1 AMAZON WEB SERVICES

AWS ACADEMY

Víctor J. González

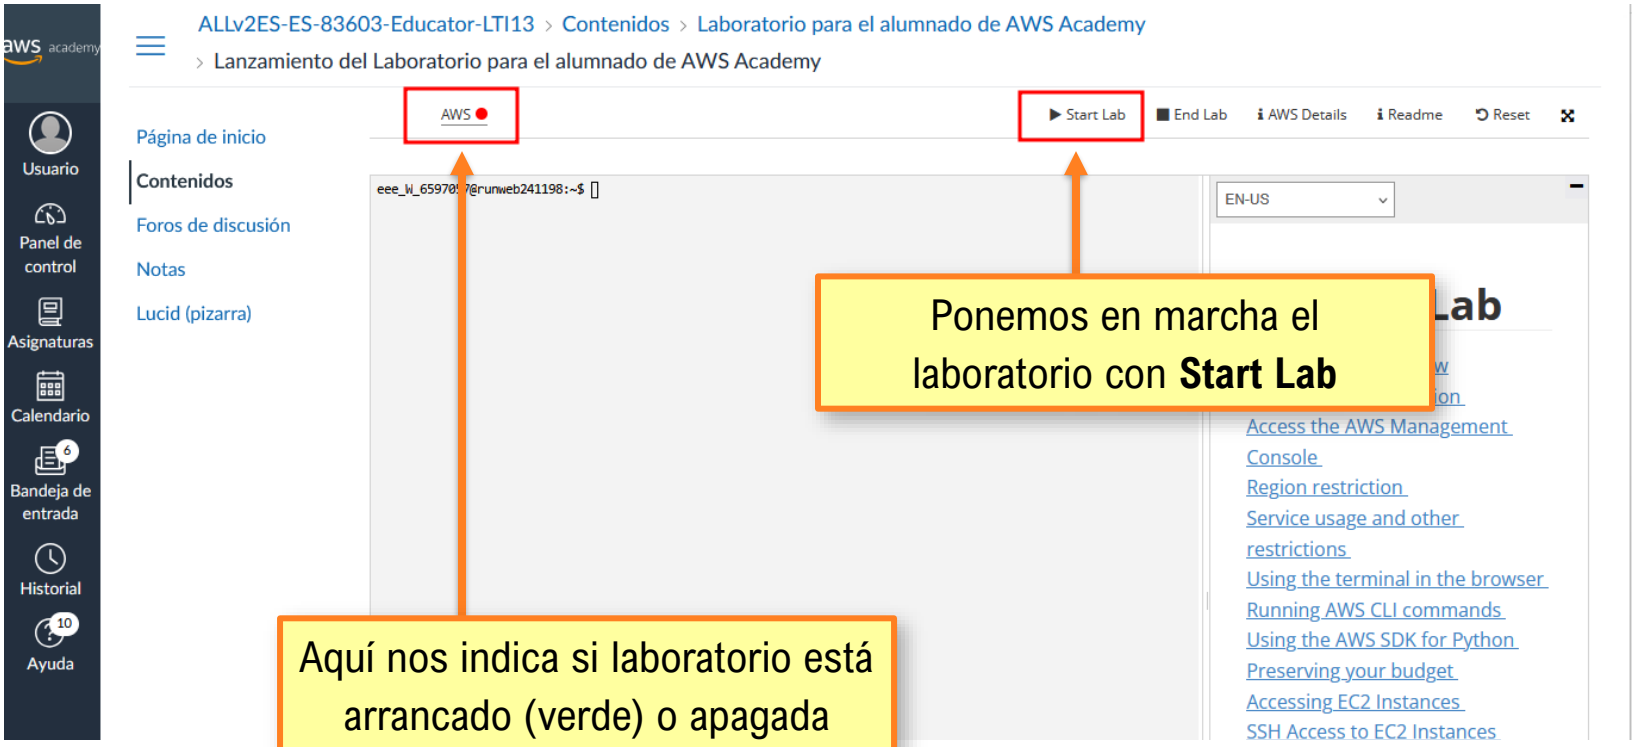
Para las prácticas con AWS trabajaremos con AWS Academy. La URL de acceso es:

https://www.awsacademy.com/vforcesite/LMS_Login



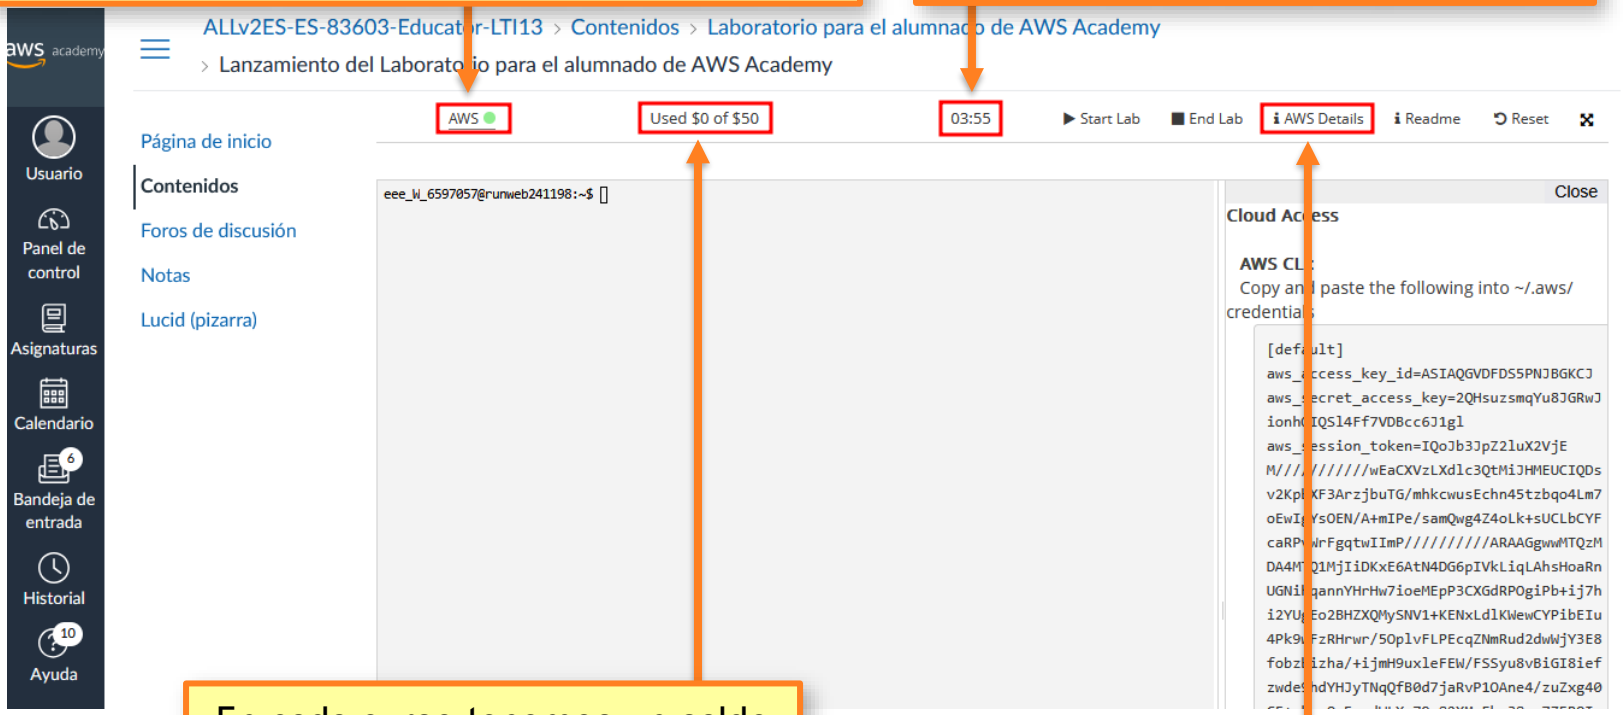
Usaremos el curso Learners Lab y, una vez ahí, deberás lanzar el laboratorio de pruebas en **Lanzamiento del Laboratorio para el alumnado de AWS Academy**




ALLv2ES-ES-83603-Educator-LTI13 › Contenidos › Laboratorio para el alumnado de AWS Academy
› Lanzamiento del Laboratorio para el alumnado de AWS Academy
Usuario
Panel de control
Asignaturas
Calendario
Bandeja de entrada
Historial
Ayuda
Página de inicio
Contenidos
Foros de discusión
Notas
Lucid (pizarra)
AWS
Start Lab
End Lab
AWS Details
Readme
Reset
EN-US
Access the AWS Management Console
Region restriction
Service usage and other restrictions
Using the terminal in the browser
Running AWS CLI commands
Using the AWS SDK for Python
Preserving your budget
Accessing EC2 Instances
SSH Access to EC2 Instances
Ponemos en marcha el laboratorio con Start Lab
Aquí nos indica si laboratorio está arrancado (verde) o apagada (rojo)

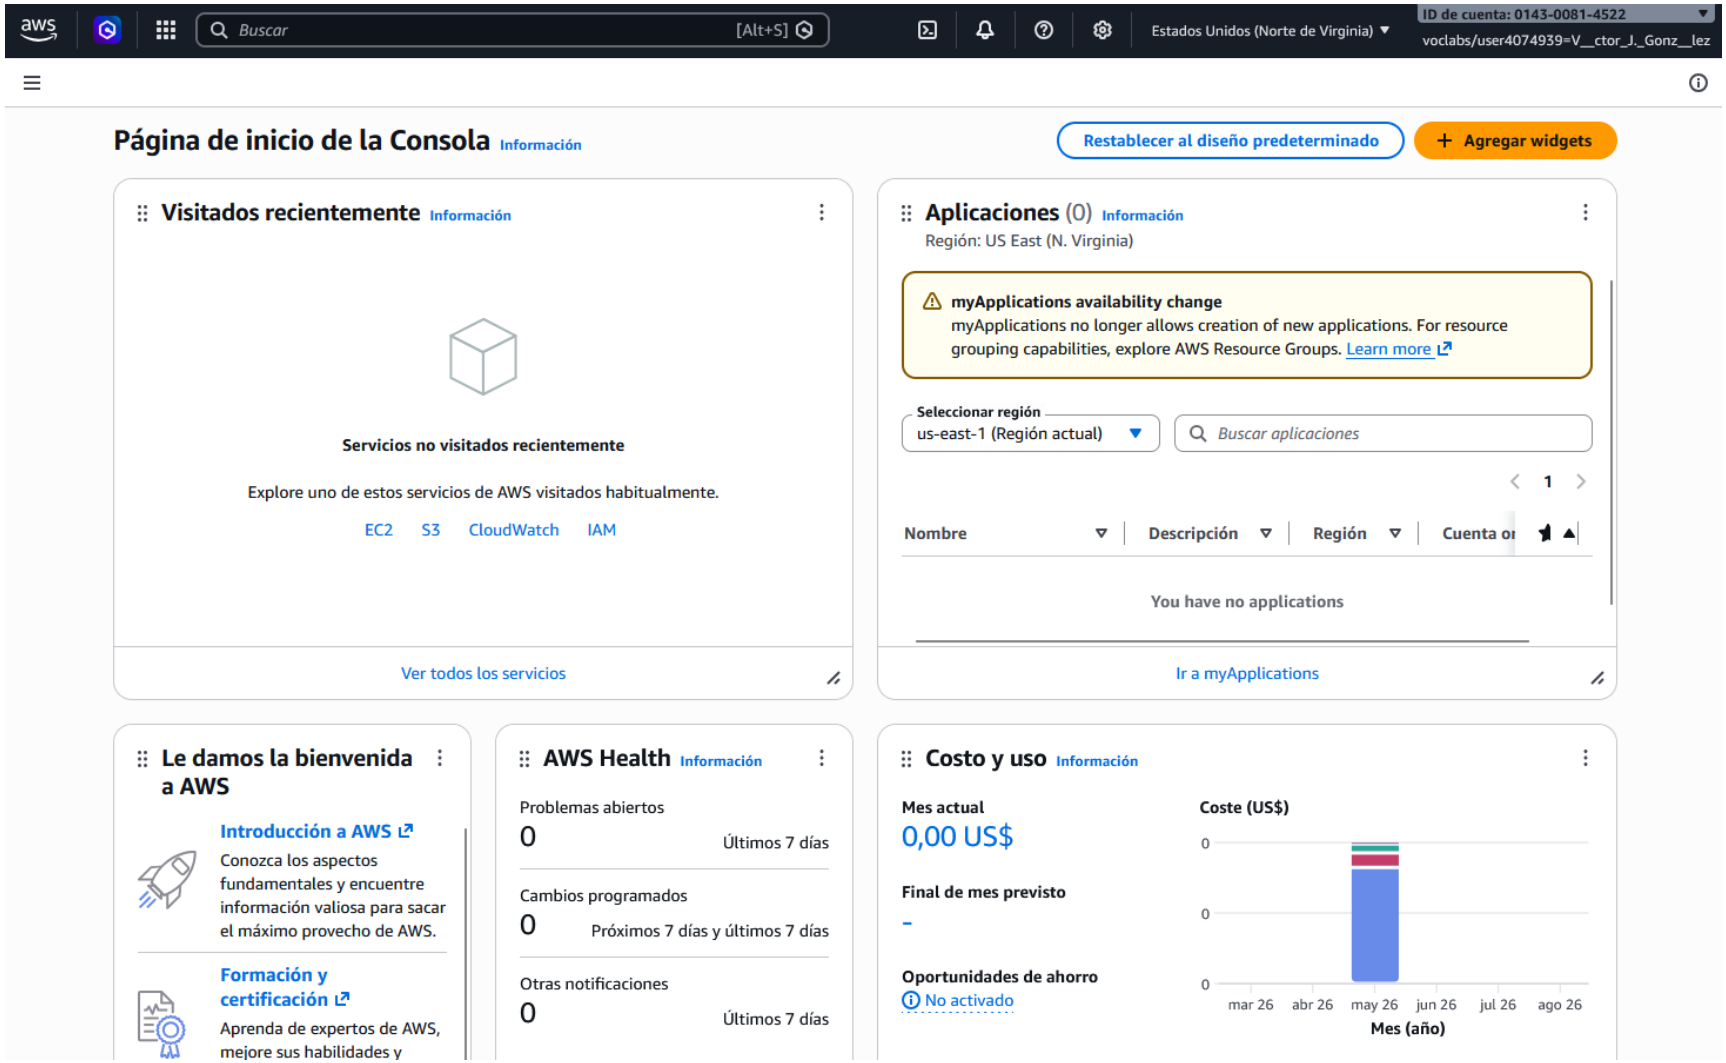
El laboratorio está **arrancado**. Haciendo click aquí podremos acceder a la interfaz web de AWS

Una limitación de los cursos es que los laboratorios **solo pueden estar arrancados 4 horas**. Tras ese tiempo todos los servicios se pausarán



En cada curso tenemos un saldo de **50$ para gastar en cualquier servicio** de AWS

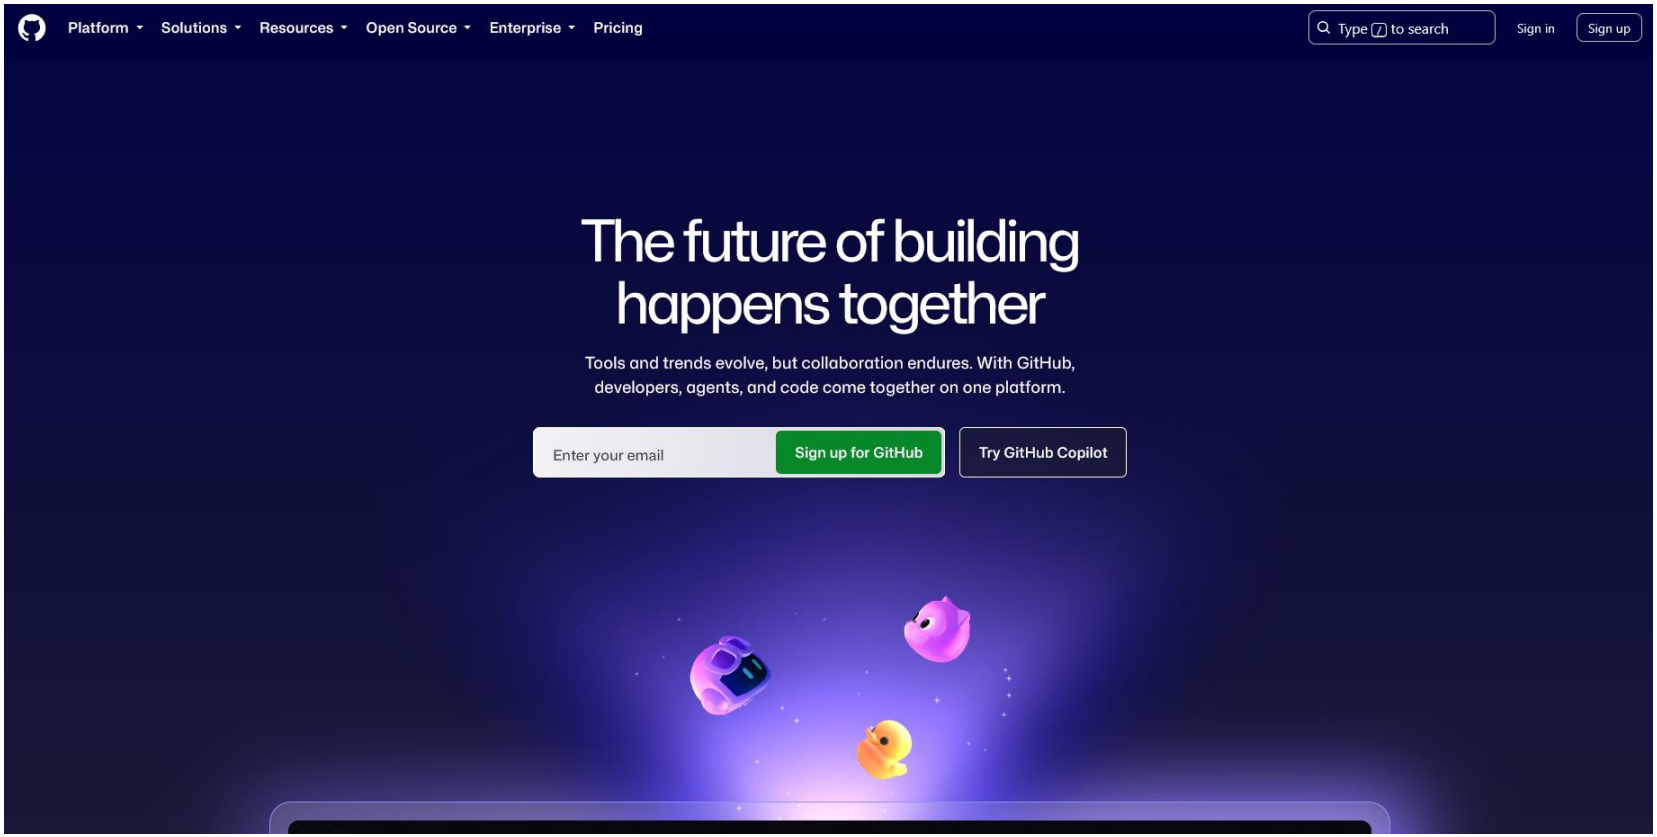
En AWS Details podremos acceder a las claves de acceso de AWS/token. Sirven para conectarnos desde AWS CLI y algún lenguaje de programación


Buscar [Alt+S]
Estados Unidos (Norte de Virginia)
ID de cuenta: 0143-0081-4522
voclabs/user4074939=V__ctor_J._Gonz__lez
Página de inicio de la Consola Información
Restablecer al diseño predeterminado
+ Agregar widgets
Visitados recientemente Información
Servicios no visitados recientemente
Explore uno de estos servicios de AWS visitados habitualmente.
EC2 S3 CloudWatch IAM
Ver todos los servicios
Aplicaciones (0) Información
Región: US East (N. Virginia)
myApplications availability change
myApplications no longer allows creation of new applications. For resource grouping capabilities, explore AWS Resource Groups. Learn more
Seleccionar región
us-east-1 (Región actual)
Buscar aplicaciones
Nombre
Descripción
Región
You have no applications
Ir a myApplications
Le damos la bienvenida a AWS
Introducción a AWS
Conozca los aspectos fundamentales y encuentre información valiosa para sacar el máximo provecho de AWS.
Formación y certificación
Aprenda de expertos de AWS, mejore sus habilidades y
AWS Health Información
Problemas abiertos
0
Últimos 7 días
Cambios programados
0
Próximos 7 días y últimos 7 días
Otras notificaciones
0
Últimos 7 días
Costo y uso Información
Mes actual
0,00 US$
Final de mes previsto
-
Oportunidades de ahorro
No activado
Coste (US$)
0
0
0
mar 26
abr 26
may 26
jun 26
jul 26
ago 26
Mes (año)

7 PREPARACIÓN DEL ENTORNO

7.2 ENTORNO LOCAL

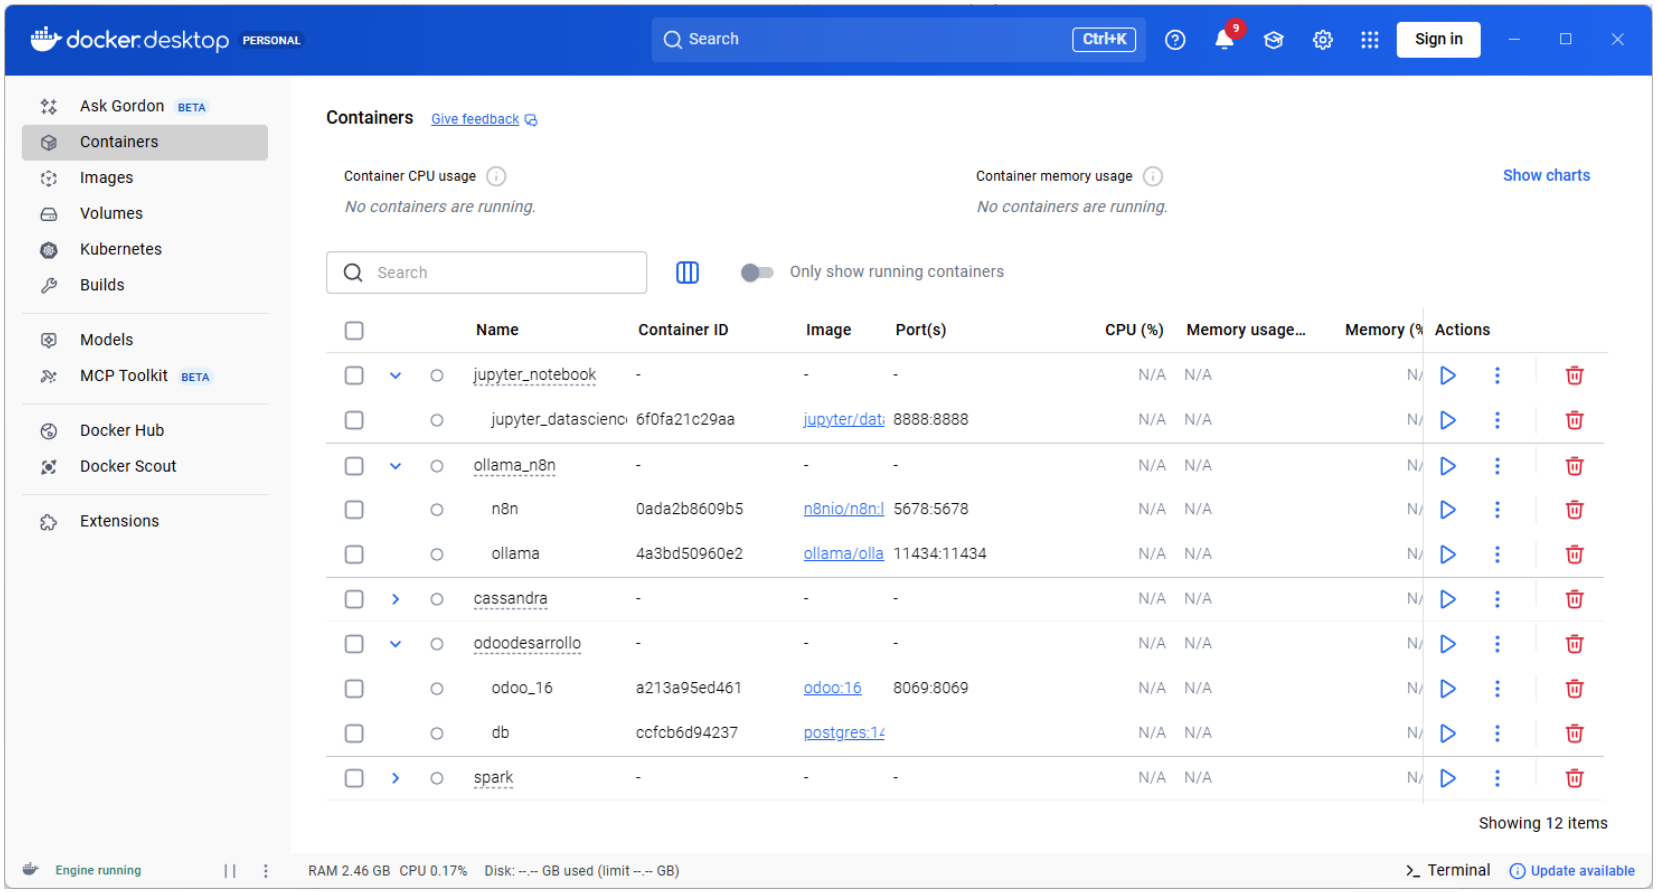
Lo primero que necesitas tener es una cuenta en GitHub para la entrega de las prácticas.



ENTORNO LOCAL

Víctor J. González

Prácticamente todos los servidores los lanzaremos en un entorno contenerizado, para lo que usaremos Docker.



Los ficheros para ejecutar cada uno de los servidores que usaremos los tienes en el siguiente repositorio de GitHub: https://vgonzalez165.github.io/docker_resources/

docker_resources

Índice del repositorio Docker

Este repositorio contiene ejemplos y recursos para Docker organizados en tres apartados principales:

- **Docker Compose** → ejemplos de despliegue de servicios.
- **Dockerfiles personalizados** → contenedores preparados simulando servidores reales, por ejemplo, bases de datos con datos precargados.
- **Recursos adicionales** → utilidades, notas y material de apoyo.

1. Docker Compose

Colección de ficheros `docker-compose.yml` para desplegar tanto servicios básicos como varios servicios combinados en un único fichero compose.

Instrucciones

Todos los servicios están conectados a una red externa denominada `shared_network`, por lo que antes de lanzar cualquiera de estos servicios será necesario tener creada esta red. En caso de no tenerla se debe crear esta red con la orden `docker network create shared_network`

Al compartir todos los servicios la misma red externa se pueden comunicar directamente cualesquiera dos servicios que se levanten utilizando la resolución local de nombres de Docker. Asimismo, cada servicio expone varios puertos en la máquina física.

Para levantar el entorno configurado en un fichero `compose` únicamente hay que ubicarse en el directorio que contiene dicho fichero y ejecutar la orden `docker compose up -d`.

Relación de ficheros `compose`

Nombre		Puertos expuestos	Función del puerto
Registry + UI	Registro privado de contenedores	5000 8085	Docker Registry Interfaz Web
Redis	Base de datos clave-valor	6379	Protocolo RESP
		7074	Interfaz Web